# Menggali Sentimen Publik melalui Berita: Studi Kasus Timnas Indonesia

**PRESENTED BY**

Team 3 - Data Analyst 2

# Agenda


| | |
|---|---|
| 3 | Introduction |
| 4 | Summary |
| 5 | Research Background |
| 6 | What Data and Tools We Used? |
| 7 | EDA |
| 8 | Step by Step |
| 10 | QnA |

# Meet Our Team

Denta Septyan Afandi
Team Leader

Ida Bagus Gede Basudewa W.
Team Member

Leo Fetri Hendli
Team Member

I Gede Surya Adi Pradana
Team Member

Dea Ananda Refiza R.
Team Member

Siti Aminah
Team Member

# Summary

## Problem

Bagaimana sentimen publik terhadap pemberitaan Timnas Indonesia?

## Challenge

- Mencari data yang cukup dari sumber yang terpercaya dan relevan
- Mengatasi permasalahan seperti bahasa gaul, singkatan, idiom, dan bahasa campuran yang sering muncul dalam diskusi online.
- Sentimen dapat dengan cepat berubah karena peristiwa terkini, seperti hasil pertandingan atau kontroversi, sehingga memerlukan model yang dinamis.

## What User Need?

- Bagaimana kita mengetahui kategori dari berita tersebut?
- Bagaimana kita tahu apakah berita ini bersifat positif, negatif, atau netral?

## Ideation

Program menggunakan bahasa pemrograman Python untuk menganalisis dataset berita timnas Indonesia sehingga menghasilkan kesimpulan yang akan disajikan dalam bentuk visualisasi data.

# Research Background

Dalam beberapa tahun terakhir, platform berita digital telah memberikan kemudahan bagi masyarakat untuk berbagi pendapat tentang berbagai topik, termasuk olahraga. Platform ini menghasilkan konten buatan pengguna dalam jumlah besar, sehingga menawarkan peluang baru untuk mengukur persepsi dan sentimen publik. Hal ini terutama berlaku untuk liputan Timnas sepak bola Indonesia yang kerap memicu perbincangan hangat di kalangan penggemar.

Analisis sentimen, salah satu cabang dari Neuro Linguistic Program (NLP), membantu menilai secara objektif reaksi masyarakat terhadap Timnas sepak bola Indonesia. Dengan menganalisis artikel berita, analisis sentimen dapat memberikan wawasan real-time mengenai opini publik, menyoroti tren seperti sentimen positif, negatif, atau netral.

Penelitian ini memberikan wawasan mengenai sentimen penggemar dan dampak media, menjembatani pelaporan subjektif dengan data objektif. Temuan ini dapat memandu manajemen tim, strategi media, dan hubungan masyarakat, sehingga menciptakan komunitas penggemar olahraga yang lebih terlibat dan terinformasi.

# DATA AND TOOLS

## Dataset berita Timnas Indonesia

| A | B | C |
|---|---|---|
| title | month | content |
| Kiper Vietnam P | Desember | Timnas Vietnam menang atas Ind |
| Piala AFF 2024: | Desember | Timnas Indonesia kalah melawan |
| Hitung-hitungan | Desember | Timnas Indonesia kalah dari Vietr |
| Statistik Indones | Desember | Tim nasional Indonesia takluk dar |
| Kerepotan & Dita | Desember | Tim nasional Indonesia harus pua |
| Susunan Pemain | Desember | Timnas Indonesia menjamu Laos |
| Meski Dikalahka | Desember | Kekalahan Timnas Indonesia dari |
| Kalau Mainnya E | Desember | Indonesia memang layak kalah da |
| STY ke Publik M | Desember | Timnas Indonesia menjamu Timna |
| Tempat Ini Bisa I | Desember | Timnas Futsal Indonesia lagi naik |

raw dataset
9607 data

| A | B | C | D | E |
|---|---|---|---|---|
| month | clean_full_text | tokens | topic | sentiment |
| desember | kiper vietnam puji ma | ['kiper', 'vietnam', 'puji | Kualifikasi Piala Dunia | Positif |
| desember | piala aff pssi sanjung | ['piala', 'aff', 'pssi', 'sa | Kualifikasi Piala Dunia | Netral |
| desember | kerepot tahan imbang | ['kerepot', 'tahan', 'imb | Kualifikasi Piala Dunia | Netral |
| desember | susun main timnas in | ['susun', 'main', 'timna | Manajemen Tim dan Pe | Positif |
| desember | kalah vietnam pede ir | ['kalah', 'vietnam', 'pe | Kualifikasi Piala Dunia | Netral |
| desember | main indonesia kalah | ['main', 'indonesia', 'ka | Hasil Pertandingan dan | Positif |
| desember | klasemen piala aff inc | ['klasemen', 'piala', 'af | Kualifikasi Piala Dunia | Netral |
| desember | vietnam indonesia ha | ['vietnam', 'indonesia' | Kualifikasi Piala Dunia | Netral |

final dataset
5369 data

## Tools

# Exploratory Data Analysis (EDA)

# JUMLAH BERITA SETIAP BULAN

```python
# Group by month and count the number of news articles
month_counts = vdata.groupby('month')['clean_full_text'].count().sort_values(ascending=False)

# Display the results
print("News Count per Month:")
month_counts
```

```
News Count per Month:
```

| month | clean_full_text |
|---|---|
| november | 981 |
| oktober | 811 |
| september | 610 |
| april | 410 |
| desember | 399 |
| mei | 397 |
| juli | 370 |
| juni | 356 |
| agustus | 341 |
| maret | 340 |
| januari | 328 |
| februari | 26 |

```python
# Bar chart & Line Chart
# Create a figure and an axes object
fig, ax1 = plt.subplots(figsize=(10, 6))

# Create the bar chart
bars = ax1.bar(month_counts.index, month_counts.values, color='skyblue', label='Bar Chart')  # Use a single color or a list of colors

# Create the line chart
ax1.plot(month_counts.index, month_counts.values, marker='o', linestyle='-', color='orange', label='Line Chart')

# Labeling
ax1.set_xlabel('Month')
ax1.set_ylabel('News Count')
ax1.set_title('Month with Most News in 2024')

# Rotate x-axis labels for better readability
plt.xticks(rotation=45)

# Add labels to the bars
for bar in bars:
    yval = bar.get_height()
    ax1.text(bar.get_x() + bar.get_width() / 2, yval, round(yval, 2), ha='center', va='bottom', fontsize=8)

# Display the plot
plt.legend()
plt.tight_layout()
plt.show()
```

Mengawali **EDA**, kita cek bulan mana yang paling sering dibanjiri berita Timnas Indoneisa! Ini bakal kasih tahu kapan media lagi heboh-hebohnya ngomongin Timnas Indonesia. Mungkin saja ada pola seru yang bisa kita temukan! Untuk ini, kita gunakan **Matplotlib** untuk visualisasi hasilnya.

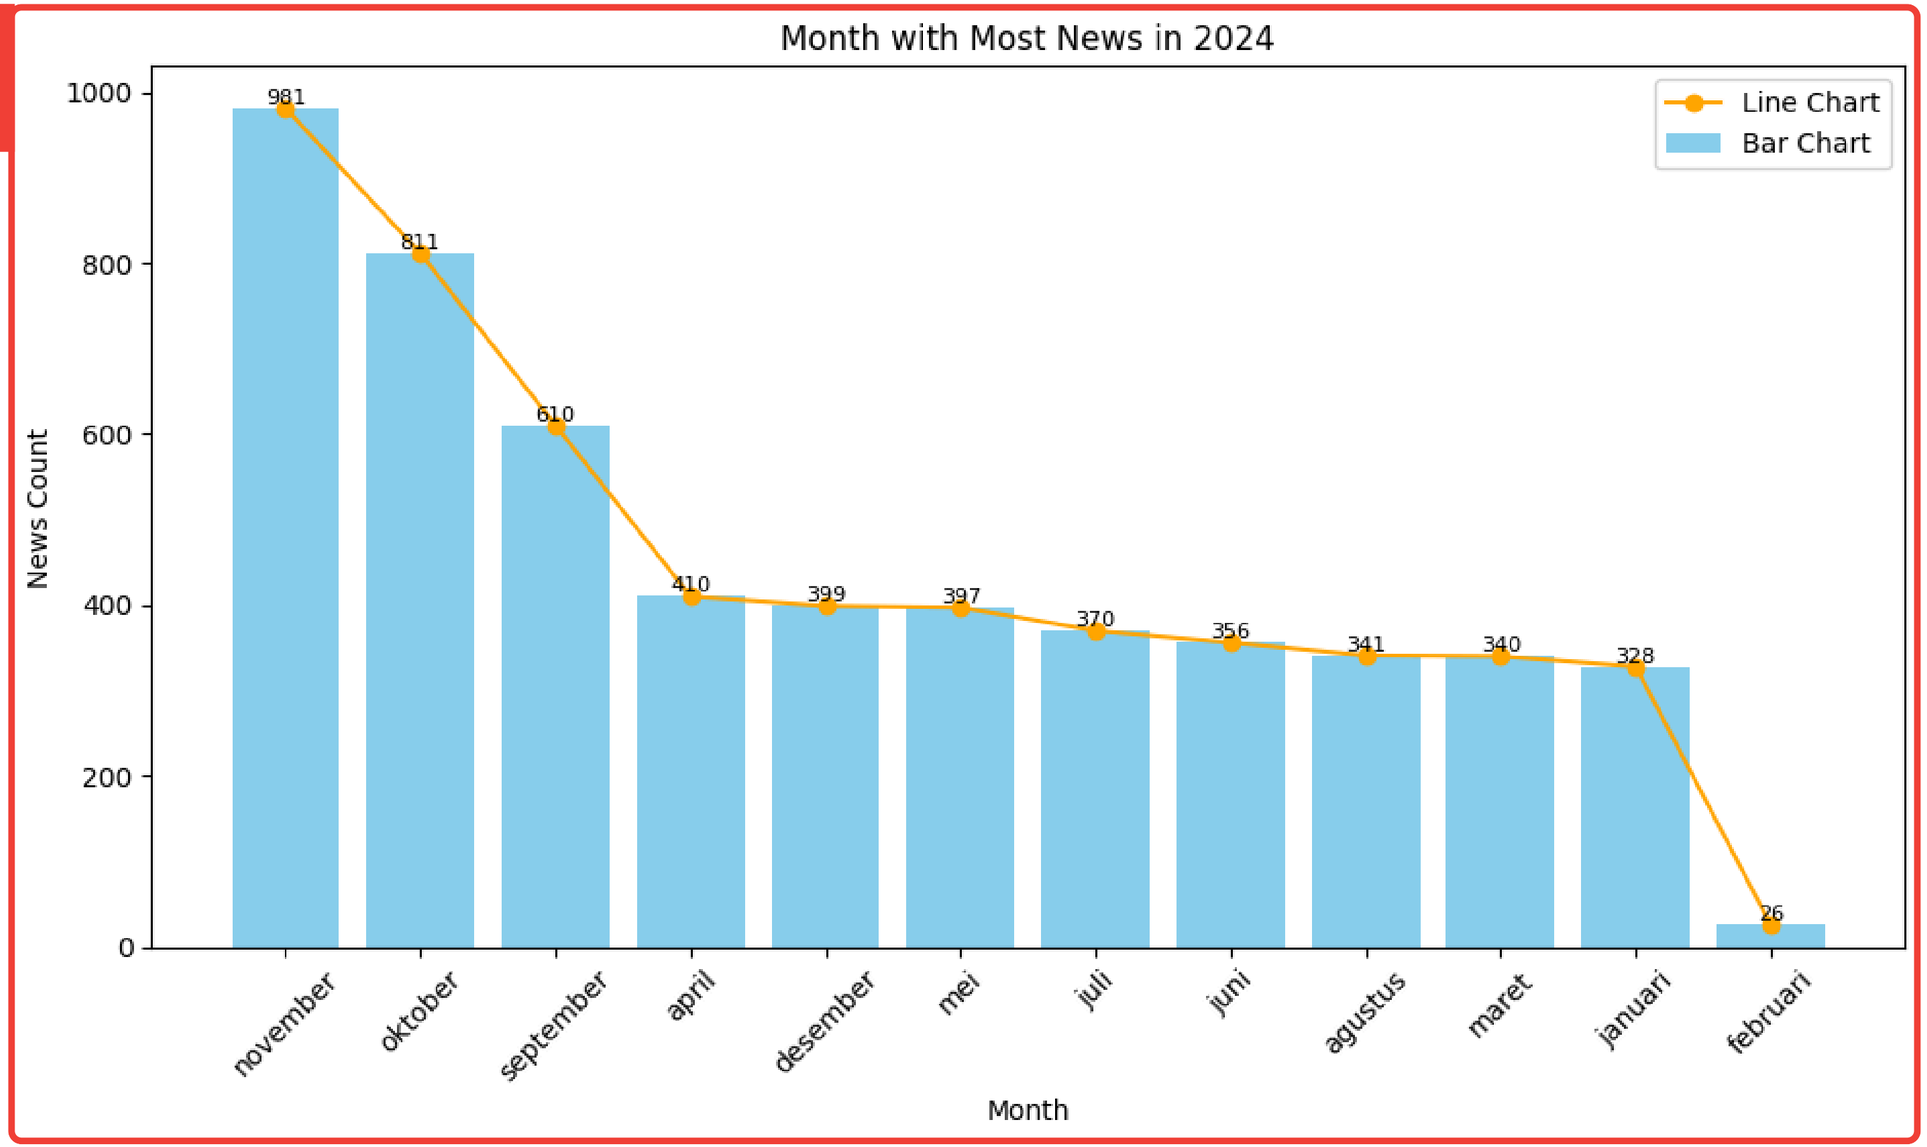
Month with Most News in 2024
Line Chart
Bar Chart
News Count
Month
1000
800
600
400
200
0
981
811
610
410
399
397
370
356
341
340
328
26
november
oktober
september
april
desember
mei
juli
juni
agustus
maret
januari
februari

# RATA-RATA PANJANG CONTENT PER BULAN

| month | avg_length |
|---|---|
| januari | 847.295732 |
| februari | 820.461538 |
| maret | 906.494118 |
| april | 879.631707 |
| mei | 868.725441 |
| juni | 848.890449 |
| juli | 843.010811 |
| agustus | 885.601173 |
| september | 892.857377 |
| oktober | 874.411837 |
| november | 901.682977 |
| desember | 825.090226 |

```python
# Calculate average title and content length per month using tokens
average_lengths = vdata.groupby('month').agg(
    {'tokens': lambda x: x.str.len().mean()}  # Calculate mean of string lengths (tokens)
).rename(columns={'tokens': 'avg_length'})

# Define the desired month order
month_order = ['januari', 'februari', 'maret', 'april', 'mei', 'juni',
               'juli', 'agustus', 'september', 'oktober', 'november', 'desember']

# Convert the index to categorical with the specified order
average_lengths.index = pd.CategoricalIndex(average_lengths.index, categories=month_order, ordered=True)

# Sort the DataFrame by the categorical index
average_lengths = average_lengths.sort_index()

# Plotting
fig, ax = plt.subplots(figsize=(12, 6))  # Use a single axes object

# Line chart for average length (tokens)
ax.plot(average_lengths.index, average_lengths['avg_length'], marker='o', linestyle='-', color='blue', label='Average Length (Tokens)')
ax.set_xlabel('Month')
ax.set_ylabel('Average Length (Tokens)', color='blue')
ax.tick_params(axis='y', labelcolor='blue')

# Customize the plot
plt.title('Average Content Length per Month (Using Tokens)')
plt.xticks(rotation=45)
plt.tight_layout()

# Display the legend
plt.legend(loc='upper left')
plt.show()

# Display the average lengths DataFrame
average_lengths
```

Mari kita bongkar! **Bulan apa yang paling rajin memberitakan tentang Timnas**, dan seberapa panjang cerita yang mereka kasih? Dengan kode ini, kita urutkan bulan-bulan sesuai kalender, lalu **cek rata-rata panjang isi berita**.

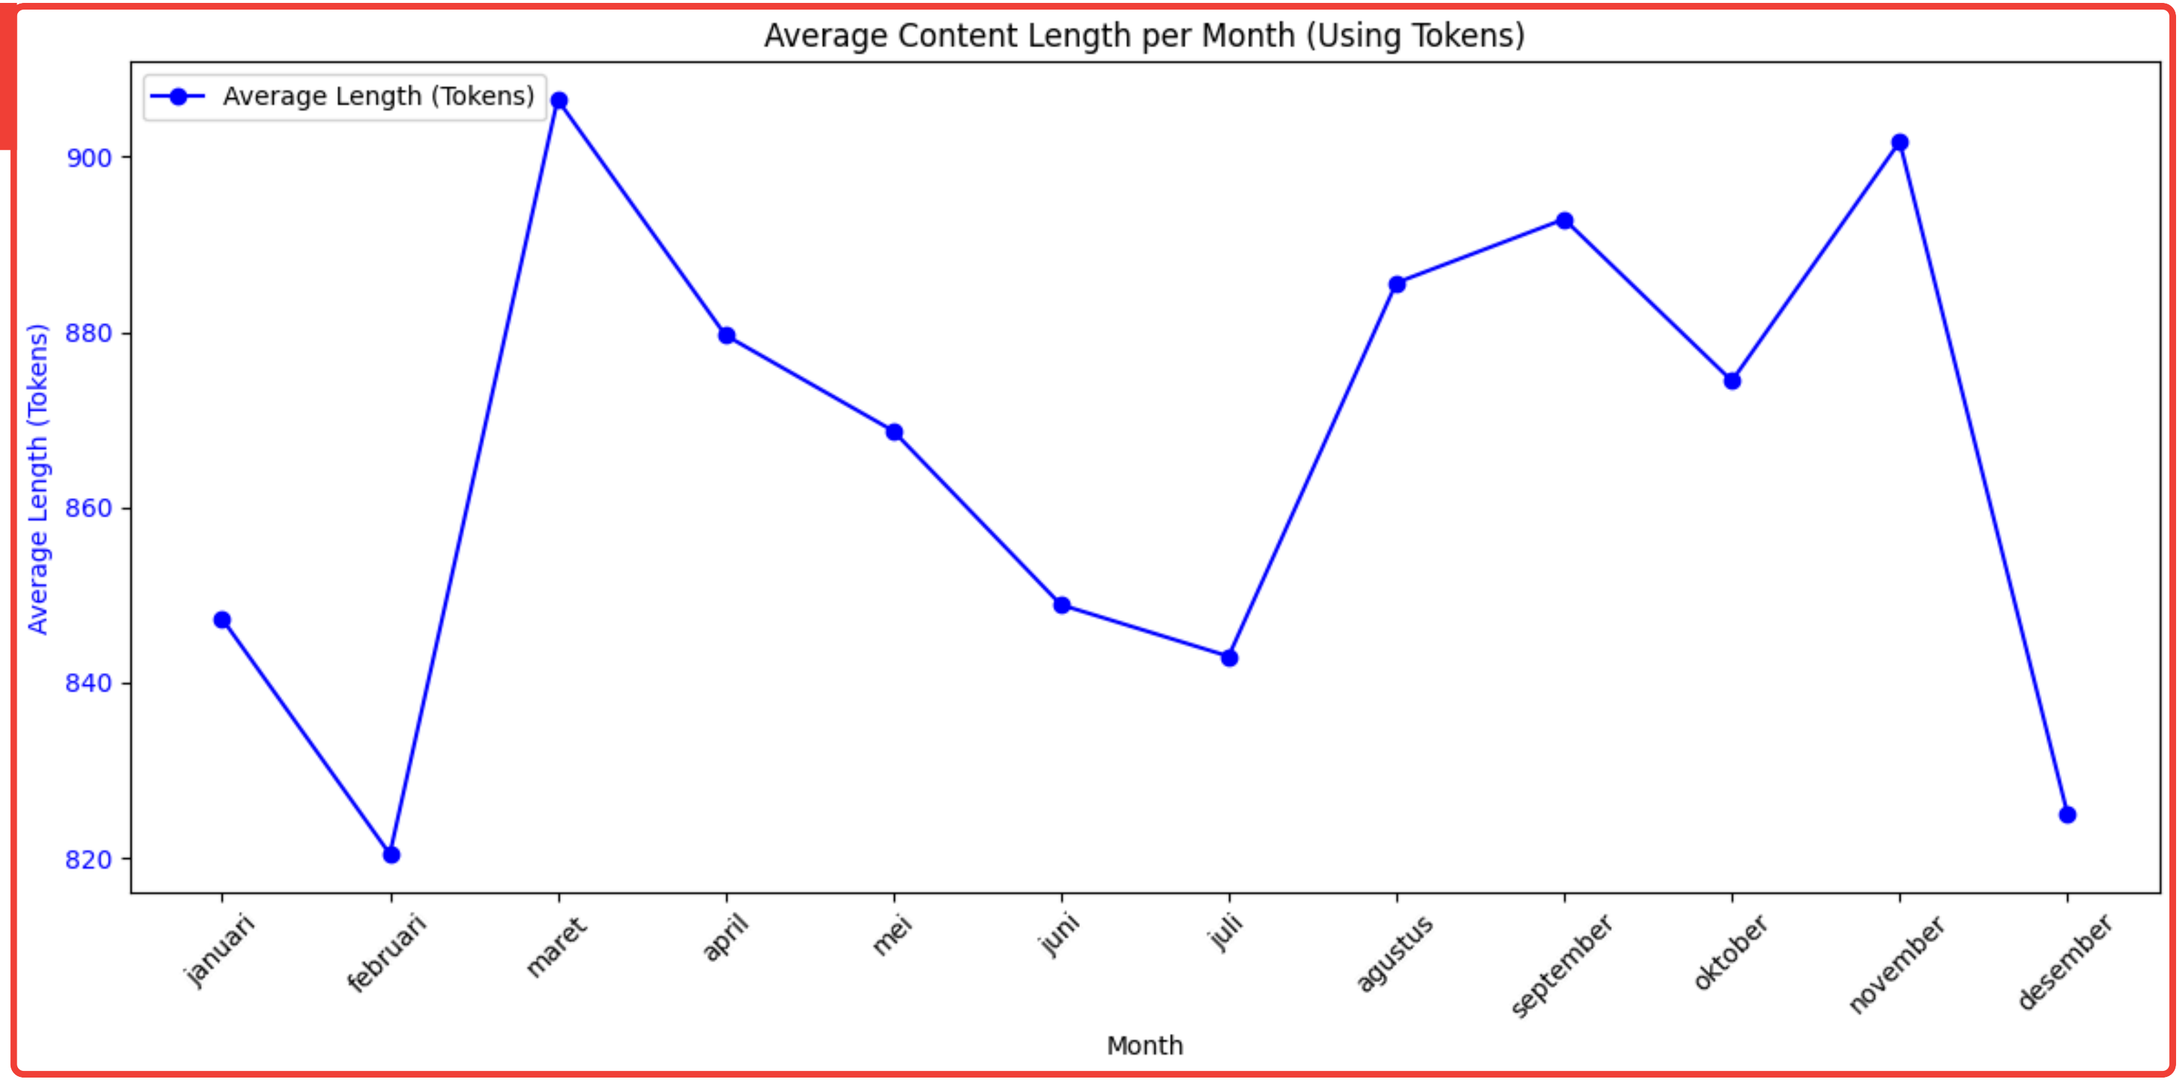
Average Content Length per Month (Using Tokens)
Average Length (Tokens)
900
880
860
840
820
Average Length (Tokens)
januari
februari
maret
april
mei
juni
juli
agustus
september
oktober
november
desember
Month

# TOTAL PANJANG CONTENT PER BULAN

```python
# Calculate total title and content length per month
total_lengths = vdata.groupby('month').agg(
    {'tokens': lambda x: x.str.len().sum()}  # Calculate sum of string lengths
).rename(columns={'tokens': 'total_length'})

# Define the desired month order
month_order = ['januari', 'februari', 'maret', 'april', 'mei', 'juni',
               'juli', 'agustus', 'september', 'oktober', 'november', 'desember']

# Convert the index to categorical with the specified order
total_lengths.index = pd.CategoricalIndex(total_lengths.index, categories=month_order, ordered=True)

# Sort the DataFrame by the categorical index
total_lengths = total_lengths.sort_index()

# Plotting
fig, ax1 = plt.subplots(figsize=(12, 6))

# Line chart for total title length
line1, = ax1.plot(total_lengths.index, total_lengths['total_length'], marker='o', linestyle='-', color='blue', label='Total Title Length')  # Assign line to line1
ax1.set_xlabel('Month')
ax1.set_ylabel('Total Title Length', color='blue')
ax1.tick_params(axis='y', labelcolor='blue')

# Customize the plot
plt.title('Total Content Length per Month')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()

# Display the total lengths DataFrame
total_lengths
```

| month | total_length |
|---|---|
| januari | 277913 |
| februari | 21332 |
| maret | 308208 |
| april | 360649 |
| mei | 344884 |
| juni | 302205 |
| juli | 311914 |
| agustus | 301990 |
| september | 544643 |
| oktober | 709148 |
| november | 884551 |
| desember | 329211 |

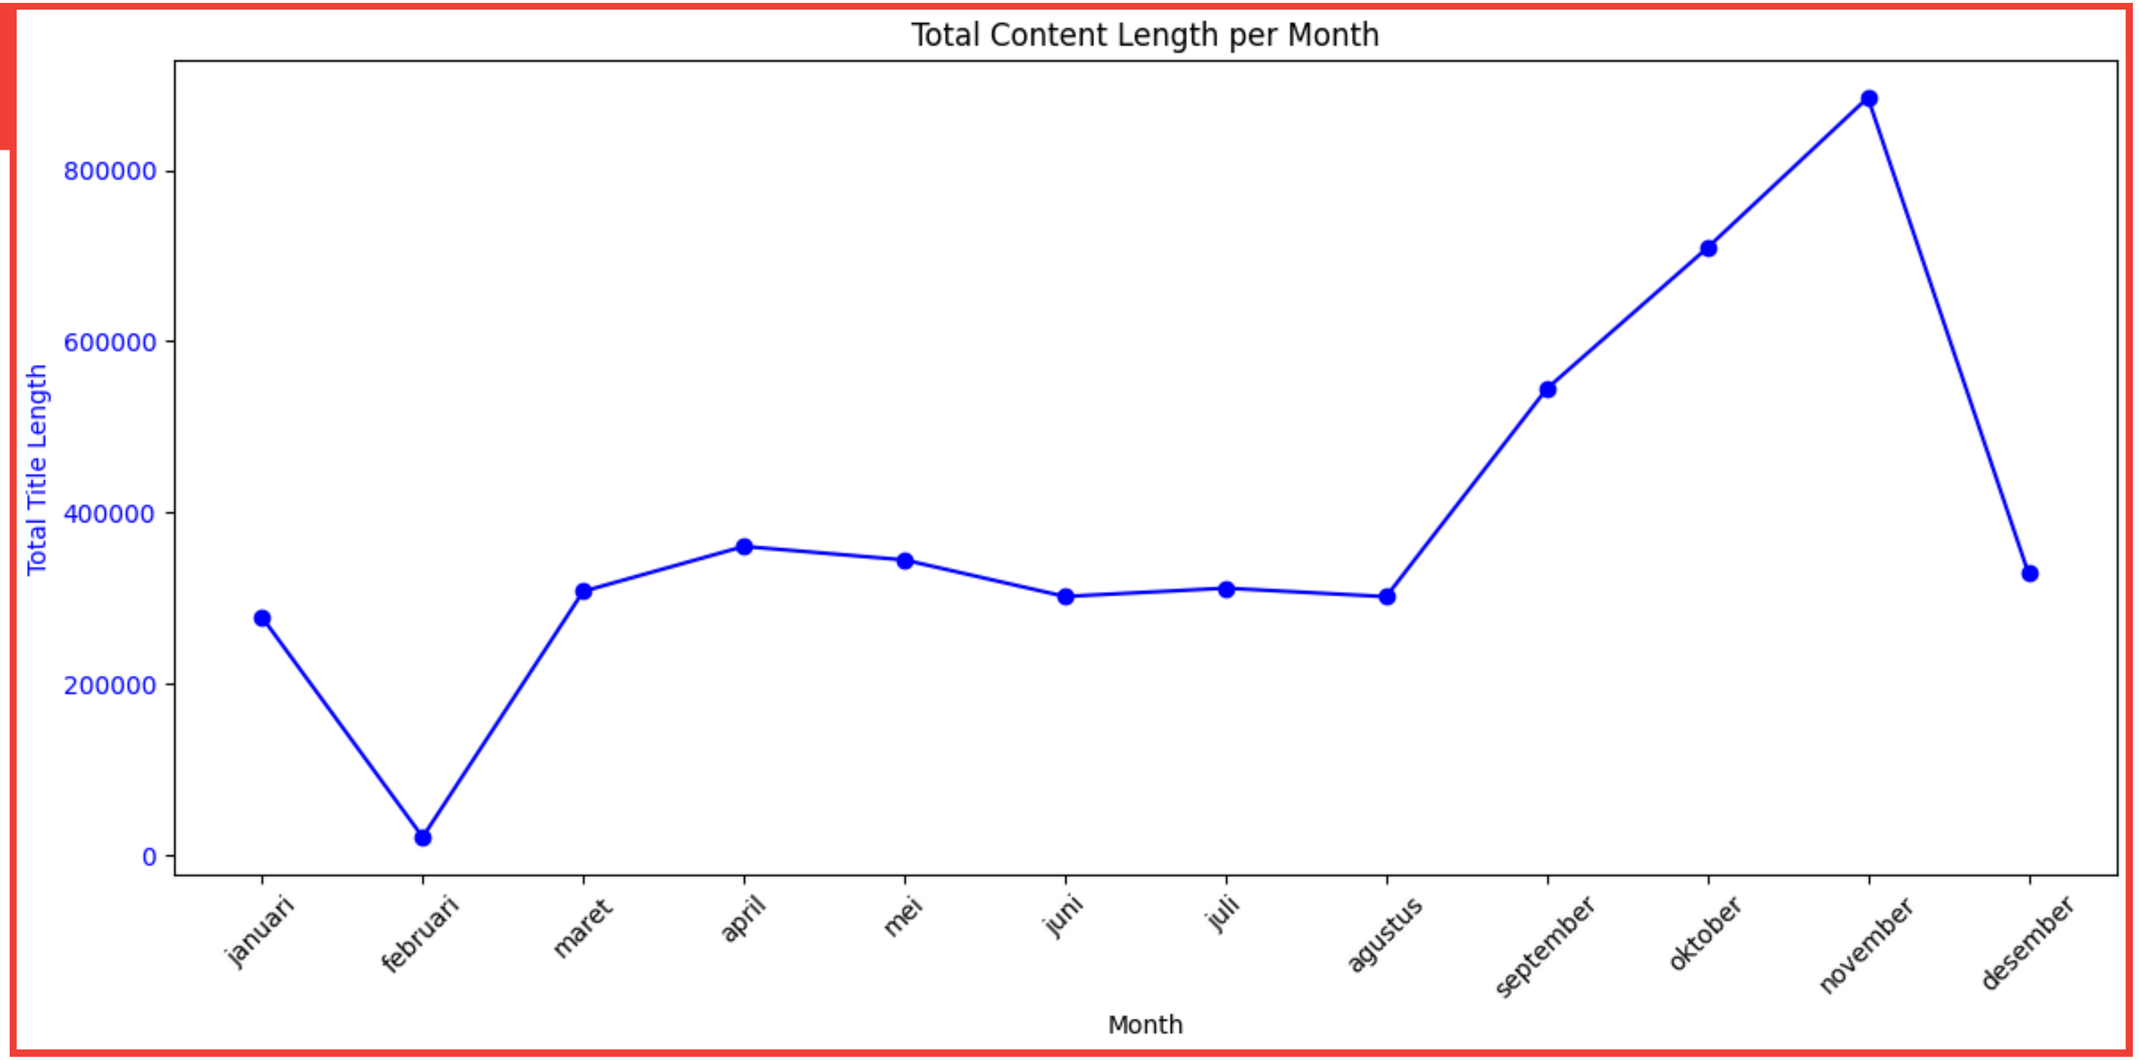
Total Content Length per Month
Total Title Length
800000
600000
400000
200000
0
januari
februari
maret
april
mei
juni
juli
agustus
september
oktober
november
desember
Month

# PERBANDINGAN SENTIMEN

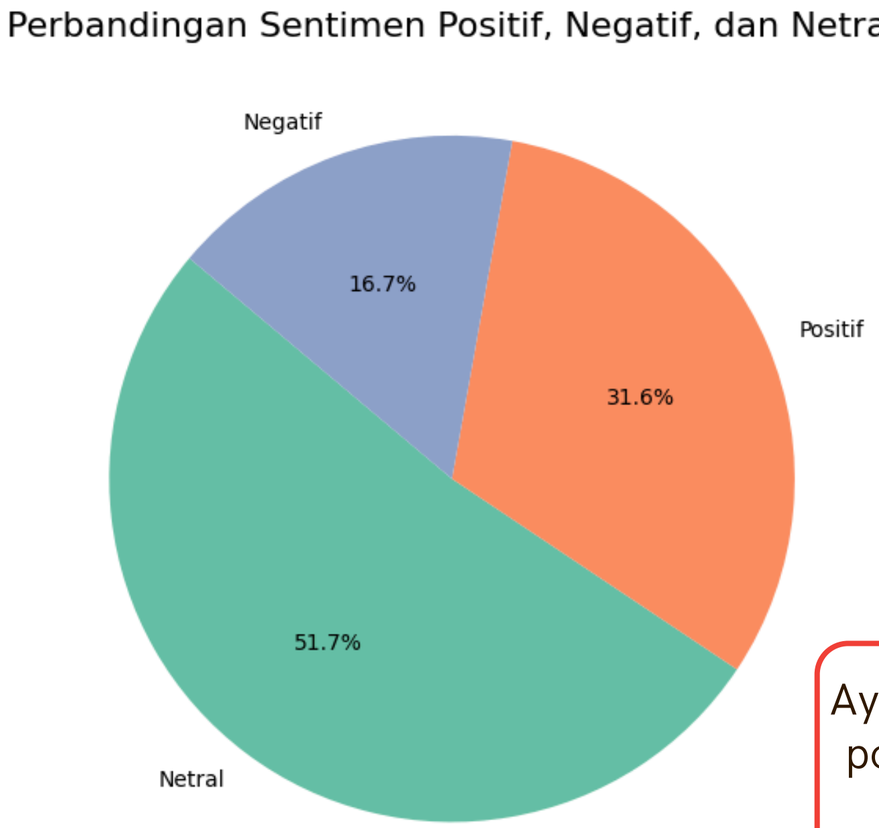


```python
# Count sentiment occurrences
sentiment_summary = vdata['sentiment'].value_counts()

# Plot the comparison of positive, negative, and neutral sentiment
plt.figure(figsize=(8, 6))
sentiment_summary.plot(
    kind='pie',
    autopct='%1.1f%%',
    startangle=140,
    colors=['#66c2a5', '#fc8d62', '#8da0cb'],
    ylabel=''
)
plt.title('Perbandingan Sentimen Positif, Negatif, dan Netral', fontsize=16)
plt.tight_layout()
plt.show()
```

Ayo kita lihat, **sentimen apa yang paling banyak muncul** di berita Timnas: positif, negatif, atau netral? Dengan **pie chart** ini, kita bisa langsung tahu suasana hati publik secara keseluruhan. Bakalan seru lihat apakah dominasi senyum, kecewa, atau biasa-biasa aja!

# PERKEMBANGAN SENTIMEN JANUARI - DESEMBER

```
# Add labels, title, and legend
plt.title('Perkembangan Sentimen Januari - Desember', fontsize=16)
plt.xlabel('Bulan', fontsize=12)
plt.ylabel('Jumlah Sentimen', fontsize=12)
plt.xticks(rotation=45)
plt.legend(title='Sentimen')
plt.grid(alpha=0.3)
plt.tight_layout()

# Show plot
plt.show()
```

Kita bikin **grafik perjalanan emosi**! Dengan kode ini, kita lihat bagaimana sentimen publik terhadap Timnas berubah dari Januari sampai Desember. Setiap garis mewakili sentimen: positif, negatif, atau netral. Jadi, kita bisa tahu bulan mana yang bikin pendukung Timnas full senyum atau sebaliknya!

```
# Filter relevant columns
filtered_data = vdata[['month', 'sentiment']]

# Standardize month names to proper casing
filtered_data['month'] = filtered_data['month'].str.capitalize()

# Define month order
month_order = ['Januari', 'Februari', 'Maret', 'April', 'Mei', 'Juni',
               'Juli', 'Agustus', 'September', 'Oktober', 'November', 'Desember']

# Group by month and sentiment, count occurrences
sentiment_counts = (
    filtered_data.groupby(['month', 'sentiment'])
    .size()
    .reset_index(name='count')
)

# Pivot data to get separate columns for each sentiment
pivot_sentiment = sentiment_counts.pivot(index='month', columns='sentiment', values='count').fillna(0)

# Reindex by month order
pivot_sentiment = pivot_sentiment.reindex(month_order)

# Plot the data
plt.figure(figsize=(12, 6))
for sentiment in pivot_sentiment.columns:
    plt.plot(pivot_sentiment.index, pivot_sentiment[sentiment], label=sentiment, marker='o')
```

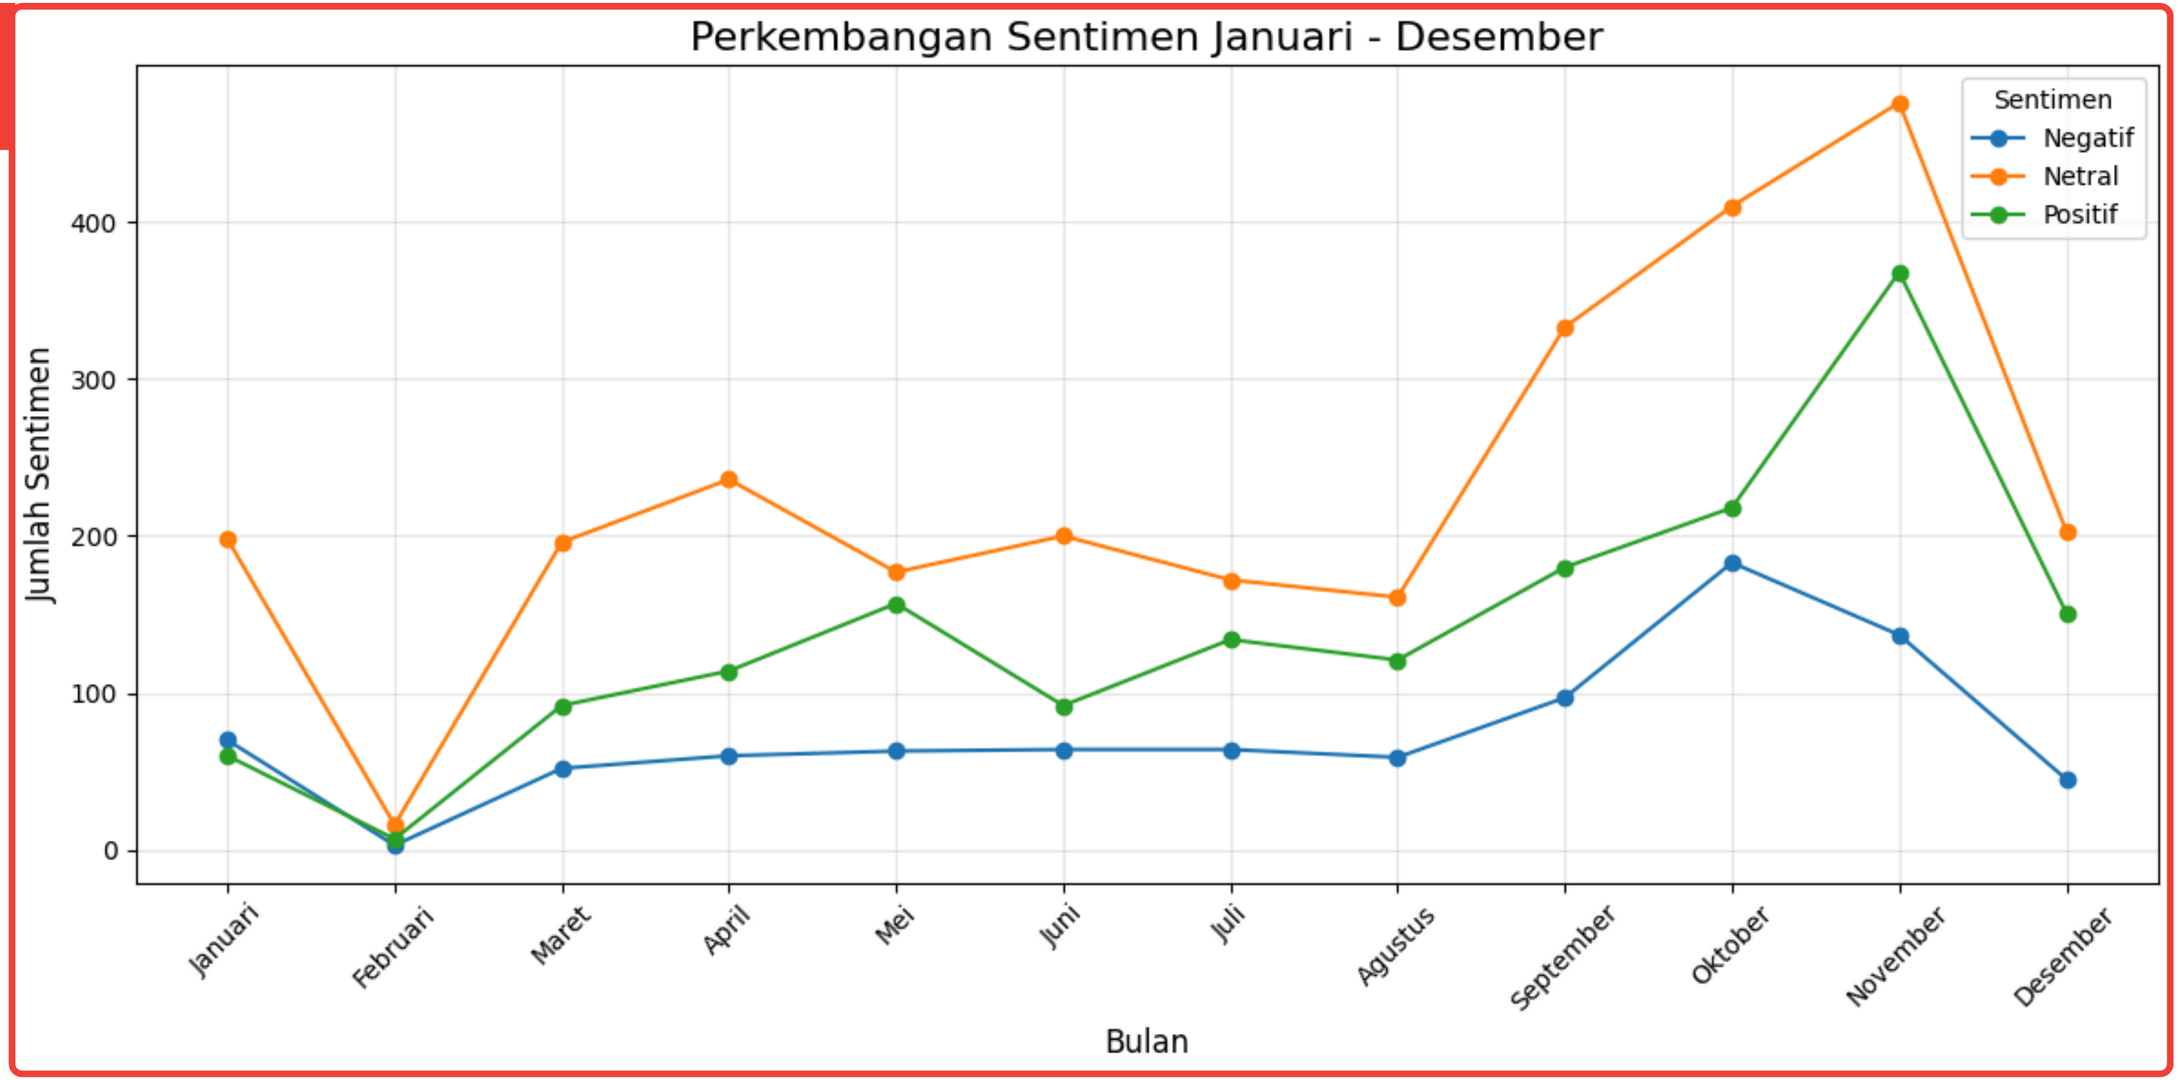
Perkembangan Sentimen Januari - Desember
Sentimen
Negatif
Netral
Positif
Jumlah Sentimen
0
100
200
300
400
Januari
Februari
Maret
April
Mei
Juni
Juli
Agustus
September
Oktober
November
Desember
Bulan

# SENTIMEN SETIAP BULAN

```python
# Create subplots for better visualization
fig, axes = plt.subplots(nrows=4, ncols=3, figsize=(15, 15))
axes = axes.flatten()  # Flatten the array for easier iteration

# Iterate through each month
for i, month in enumerate(pivot_sentiment.index):
    ax = axes[i]
    data = pivot_sentiment.loc[month]

    # Create a bar chart for each sentiment in the current month
    ax.bar(data.index, data.values)
    ax.set_title(month)
    ax.set_xlabel("Sentiment")
    ax.set_ylabel("Count")
    ax.tick_params(axis="x", rotation=45)

# Remove any unused subplots
for j in range(i + 1, len(axes)):
    fig.delaxes(axes[j])

plt.tight_layout()
plt.show()
```

Bayangkan punya kalender yang bisa bicara! Kode ini bikin **grafik batang** untuk setiap bulan dari Januari sampai Desember, menunjukkan **bagaimana sentimen** (positif, negatif, netral) **bermain di setiap bulan.** Dengan bantuan Matplotlib, tiap bulan jadi punya panggung sendiri di subplot yang rapih!

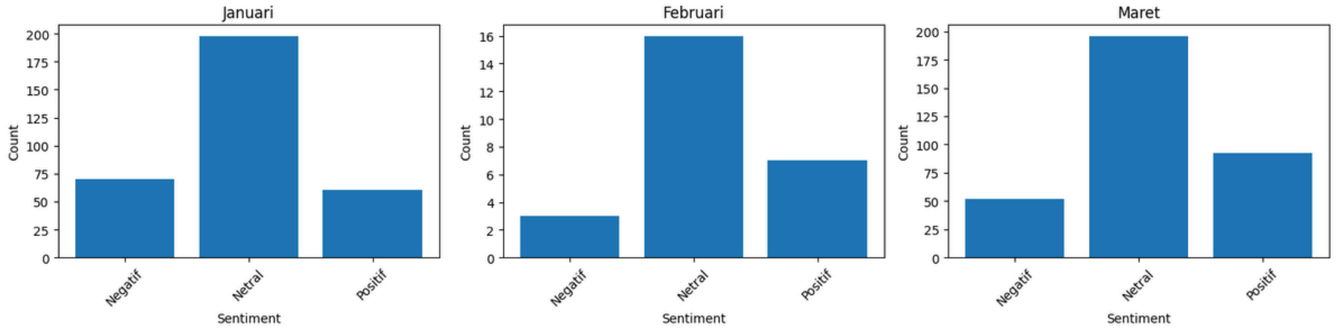








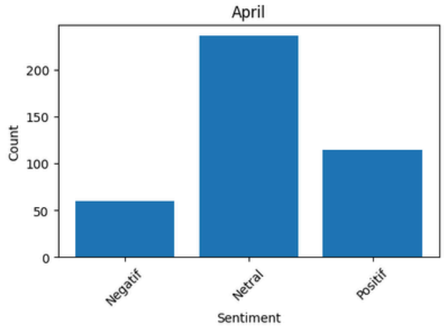


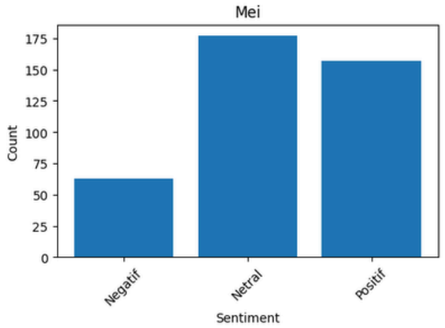


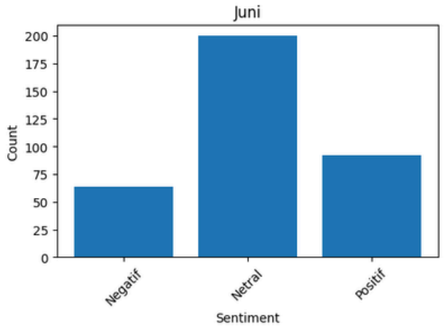


**NETRAL MENDOMINASI!**

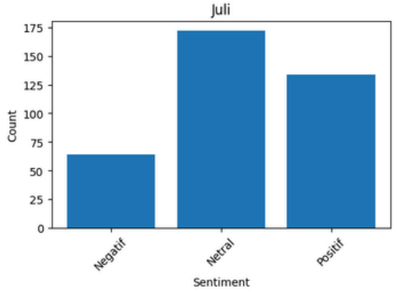


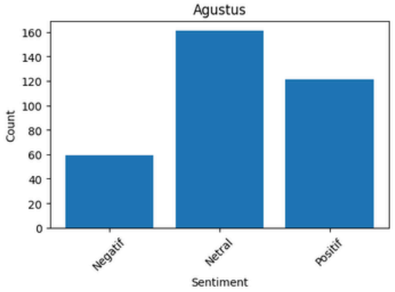


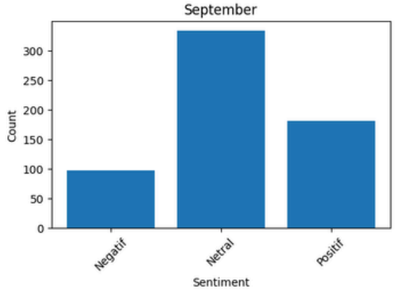


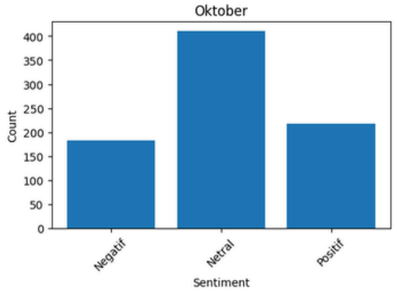


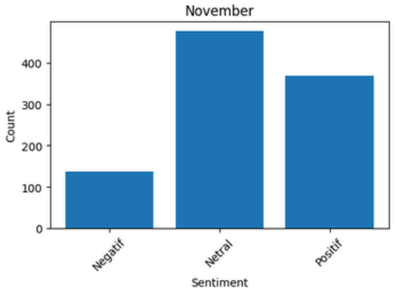


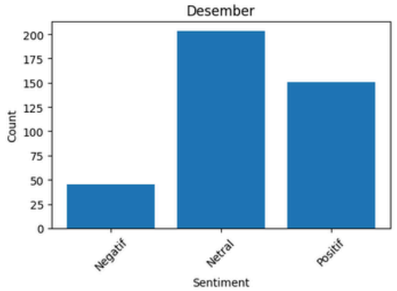

# PERBANDINGAN SENTIMEN POSITIF VS NEGATIF

Siapa yang menang, tim ‘Senang’ (positif) atau tim ‘Susah’ (negatif)? Kode ini bikin **grafik batang berdampingan** untuk tiap bulan, biar kita bisa langsung tahu siapa yang mendominasi berita. Dengan bantuan **Numpy** dan **Matplotlib**, duel antara dua sentimen jadi jelas banget!

```
import numpy as np

# Create a bar chart comparing positive and negative sentiments for each month
plt.figure(figsize=(12, 6))
width = 0.35  # Width of the bars

# Ensure 'Positif' and 'Negatif' columns exist in pivot_sentiment
if 'Positif' in pivot_sentiment.columns and 'Negatif' in pivot_sentiment.columns:
    positive_sentiments = pivot_sentiment['Positif']
    negative_sentiments = pivot_sentiment['Negatif']

    x = np.arange(len(pivot_sentiment.index))  # Location for the bars

    # Create bars for positive and negative sentiments
    plt.bar(x - width/2, positive_sentiments, width, label='Positif', color='green')
    plt.bar(x + width/2, negative_sentiments, width, label='Negatif', color='red')

    # Add labels and title
    plt.xlabel('Bulan', fontsize=12)
    plt.ylabel('Jumlah Sentimen', fontsize=12)
    plt.title('Perbandingan Sentimen Positif vs Negatif', fontsize=16)
    plt.xticks(x, pivot_sentiment.index, rotation=45)  # Set x-axis ticks to month names
    plt.legend()
    plt.tight_layout()
    plt.grid(axis='y', alpha=0.3)

    # Display the plot
    plt.show()
else:
    print("Kolom 'Positif' atau 'Negatif' tidak ditemukan dalam data pivot_sentiment.")
```

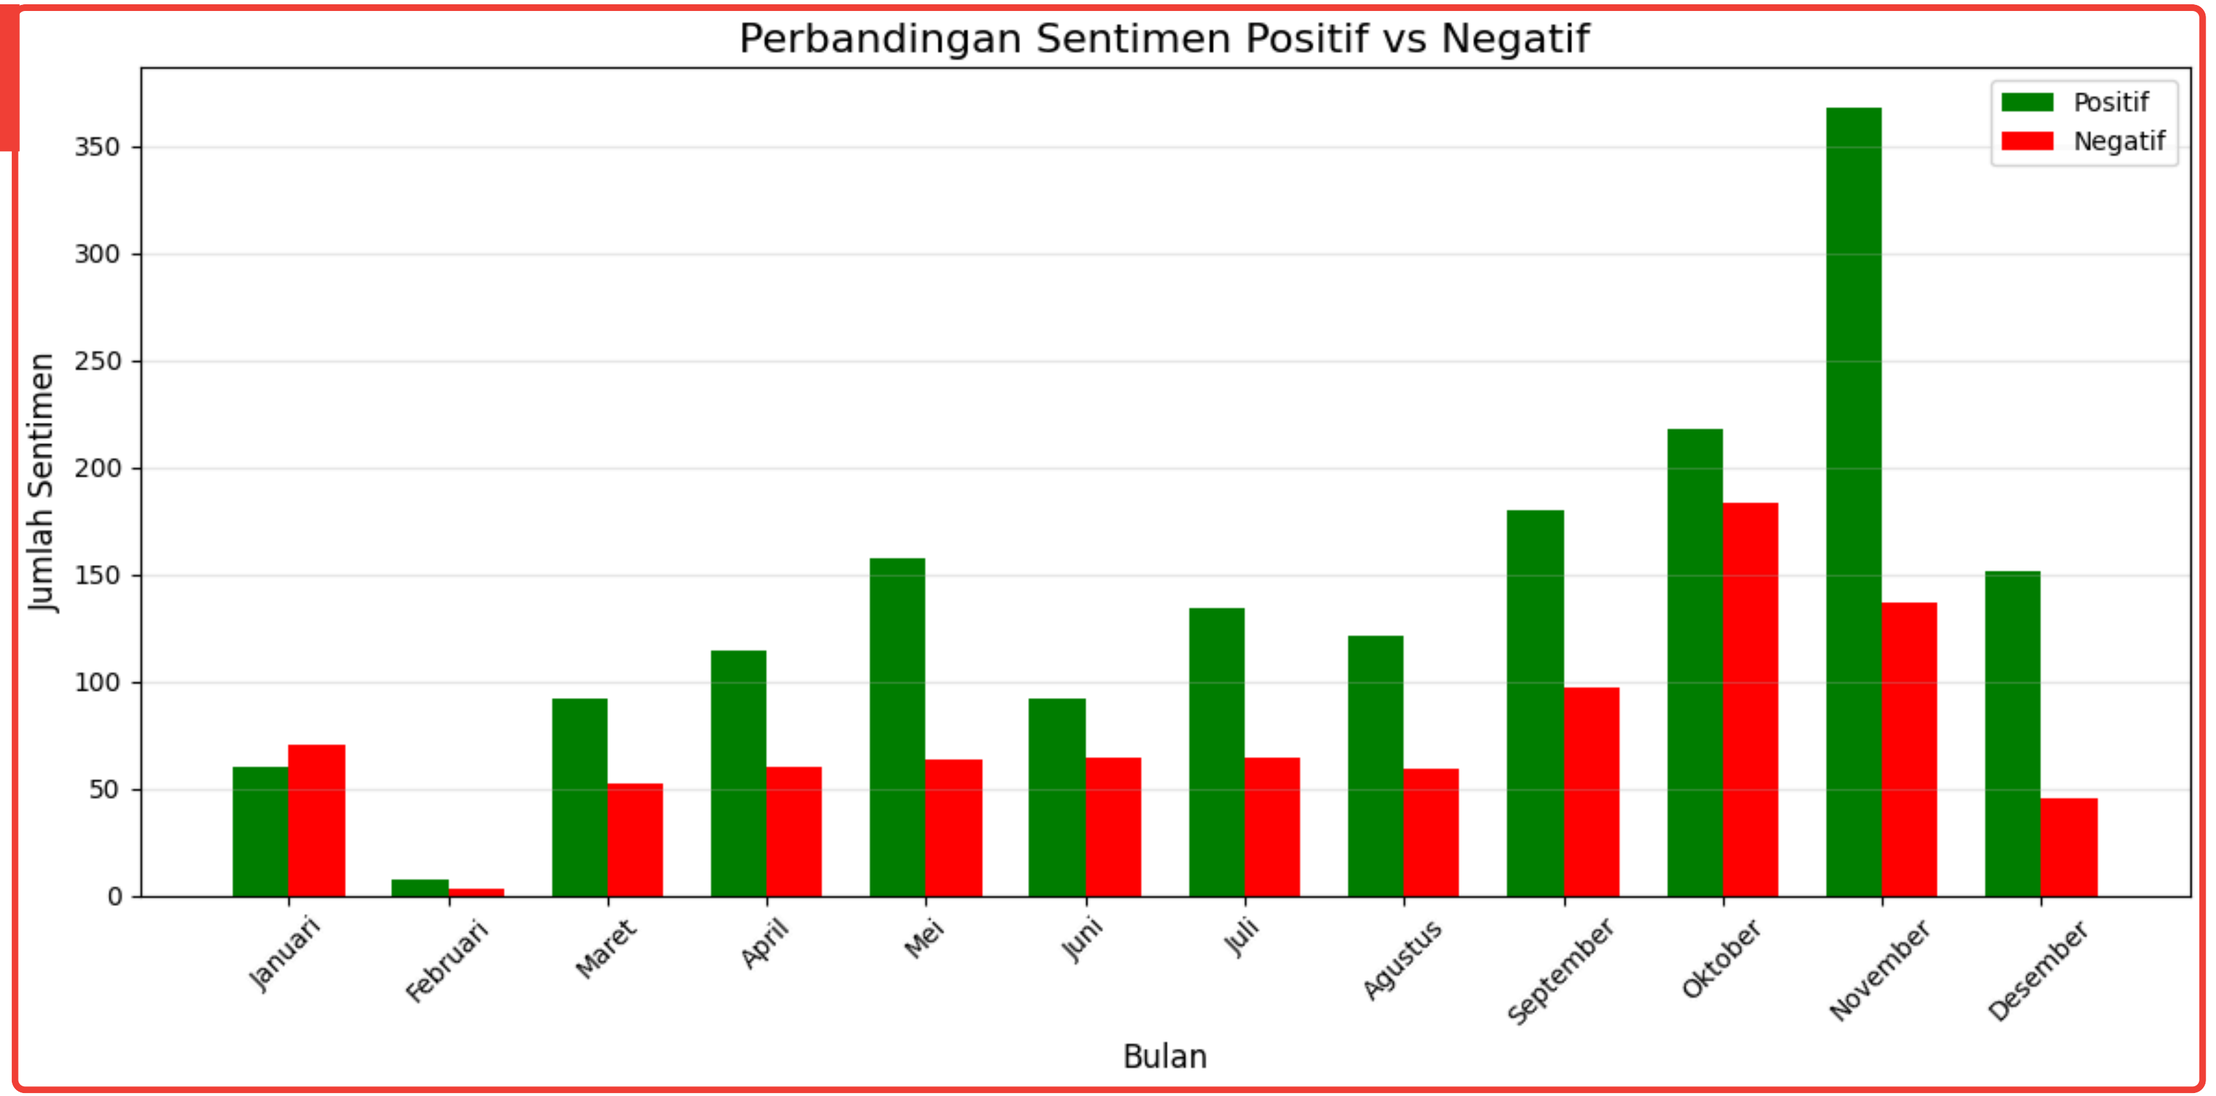
Perbandingan Sentimen Positif vs Negatif
Positif
Negatif
Jumlah Sentimen
0
50
100
150
200
250
300
350
Januari
Februari
Maret
April
Mei
Juni
Juli
Agustus
September
Oktober
November
Desember
Bulan

# PERKEMBANGAN TOPIK DOMINAN

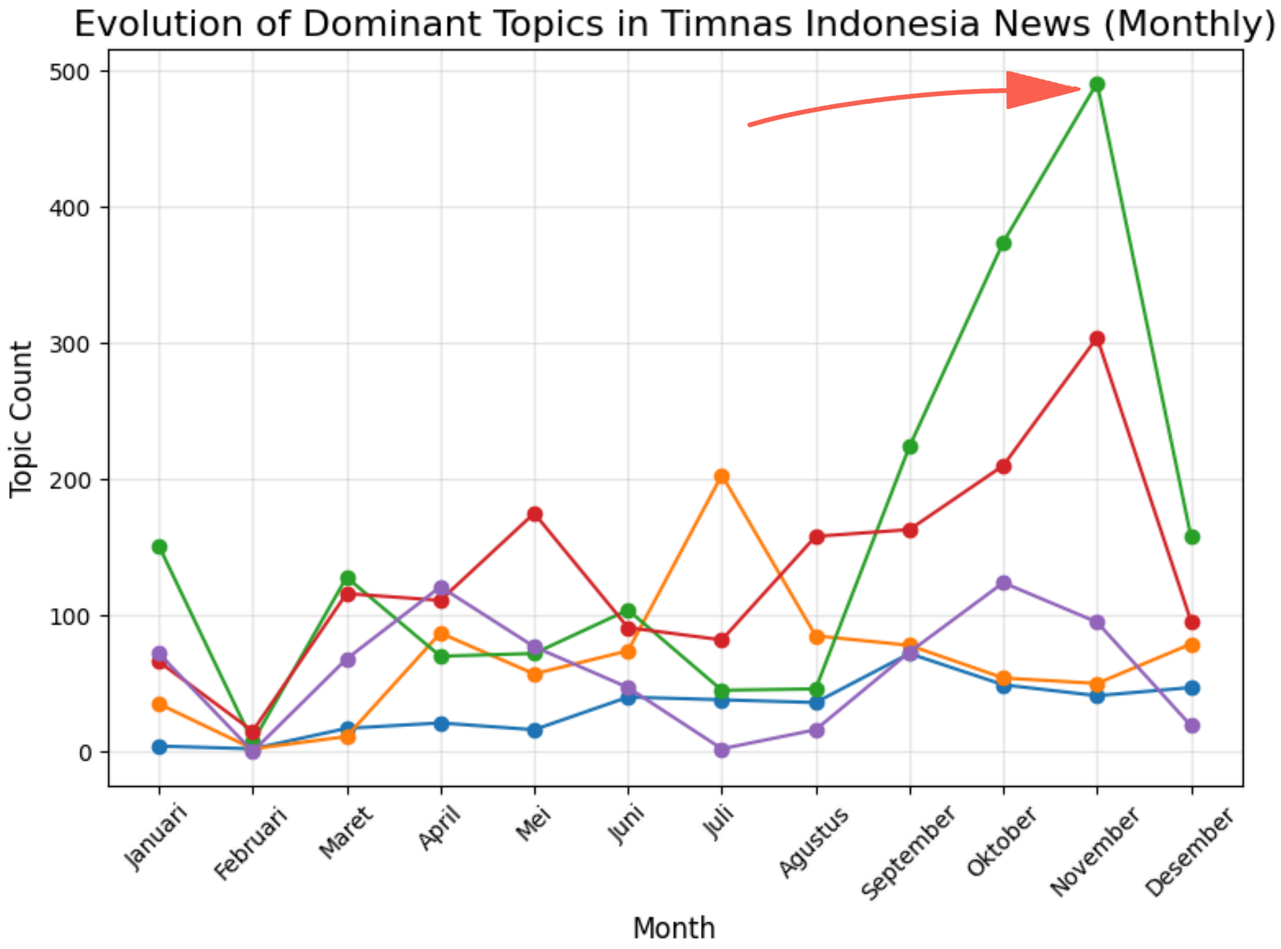


```python
plt.figure(figsize=(12, 6))
for topic in pivot_sentiment.columns:
    plt.plot(pivot_sentiment.index, pivot_sentiment[topic], label=topic, marker='o')

plt.title('Evolution of Dominant Topics in Timnas Indonesia News (Monthly)', fontsize=16)
plt.xlabel('Month', fontsize=12)
plt.ylabel('Topic Count', fontsize=12)
plt.xticks(rotation=45)
plt.legend(title='Topic', bbox_to_anchor=(1.05, 1), loc='upper left') # Improved legend placement
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```

Lonjakan yang sangat signifikan pada topik **“Kualifikasi Piala Dunia”**

# MORE INFO

Berapa aja sih jumlah dari setiap Topiknya dalam kurun 1 tahun ini?

```python
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# Create the heatmap using seaborn
plt.figure(figsize=(12, 6))
sns.heatmap(pivot_sentiment, annot=True, fmt=".2f", cmap="viridis", linewidths=.5)

# Add labels and title
plt.title('Perkembangan Topic Pembicaraan Januari - Desember', fontsize=16)
plt.xlabel('Topic', fontsize=12)
plt.ylabel('Bulan', fontsize=12)
plt.xticks(rotation=45, ha='right')

# Show plot
plt.show()
```

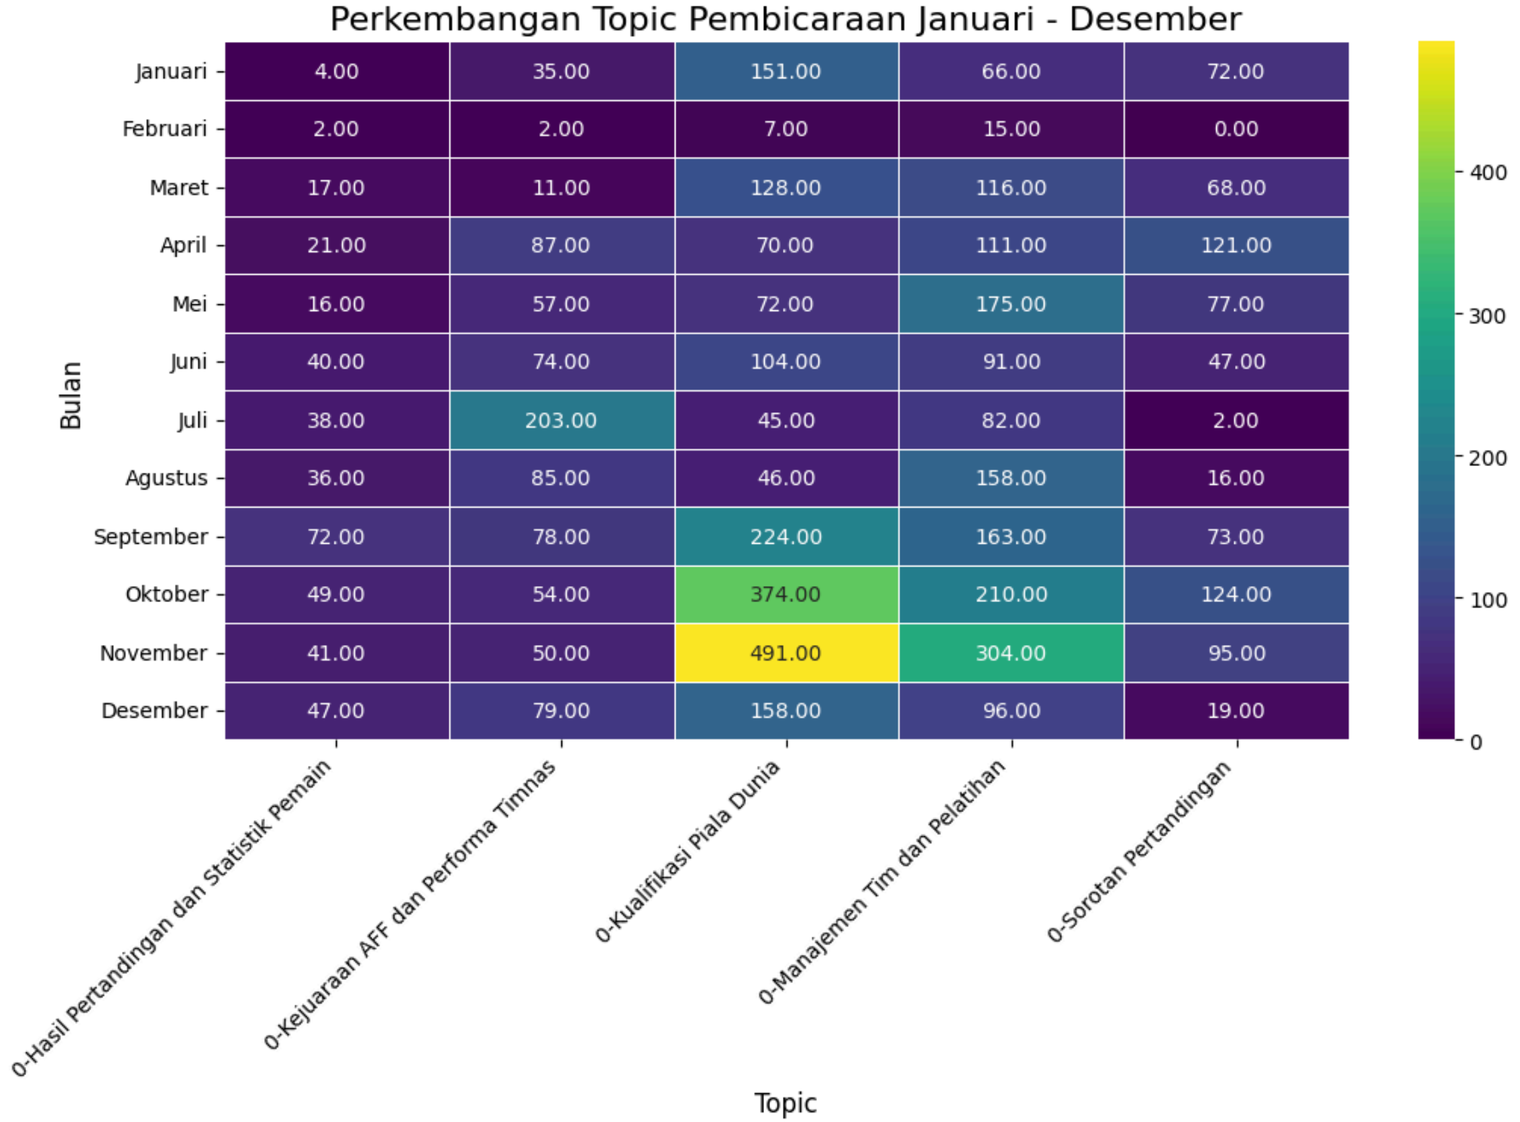

# TREN KATA PER BULAN

```python
def count_dominant_words(df, month, top_n=10):
    """Counts the dominant words for a given month."""

    month_data = vdata[vdata['month'] == month]
    all_words = []
    for tokens in month_data['tokens']:
      if isinstance(tokens, str):  # Check if tokens is a string
        try:
            all_words.extend(eval(tokens))  # Safely evaluate string representation of the list
        except (NameError, SyntaxError):
            print(f"Skipping invalid 'tokens' value: {tokens}")
            continue  # Skip to the next iteration

    word_counts = {}
    for word in all_words:
      word_counts[word] = word_counts.get(word, 0) + 1

    sorted_word_counts = sorted(word_counts.items(), key=lambda x: x[1], reverse=True)

    return dict(sorted_word_counts[:top_n])

# Create a dictionary to store dominant words for each month
dominant_words_per_month = {}

for month in vdata['month'].unique():
    dominant_words_per_month[month] = count_dominant_words(vdata, month)
```

```python
# Convert dominant_words_per_month to a DataFrame for easier visualization
dominant_words_vdata = pd.DataFrame(dominant_words_per_month).fillna(0).astype(int)


# Plot the heatmap using seaborn
plt.figure(figsize=(12, 6))
sns.heatmap(dominant_words_vdata, annot=True, fmt="d", cmap="viridis", linewidths=.5)

# Add labels and title
plt.title('Tren Kata Dominan Per Bulan', fontsize=16)
plt.xlabel('Kata', fontsize=12)
plt.ylabel('Bulan', fontsize=12)
plt.xticks(rotation=45, ha='right')

# Show plot
plt.show()
```

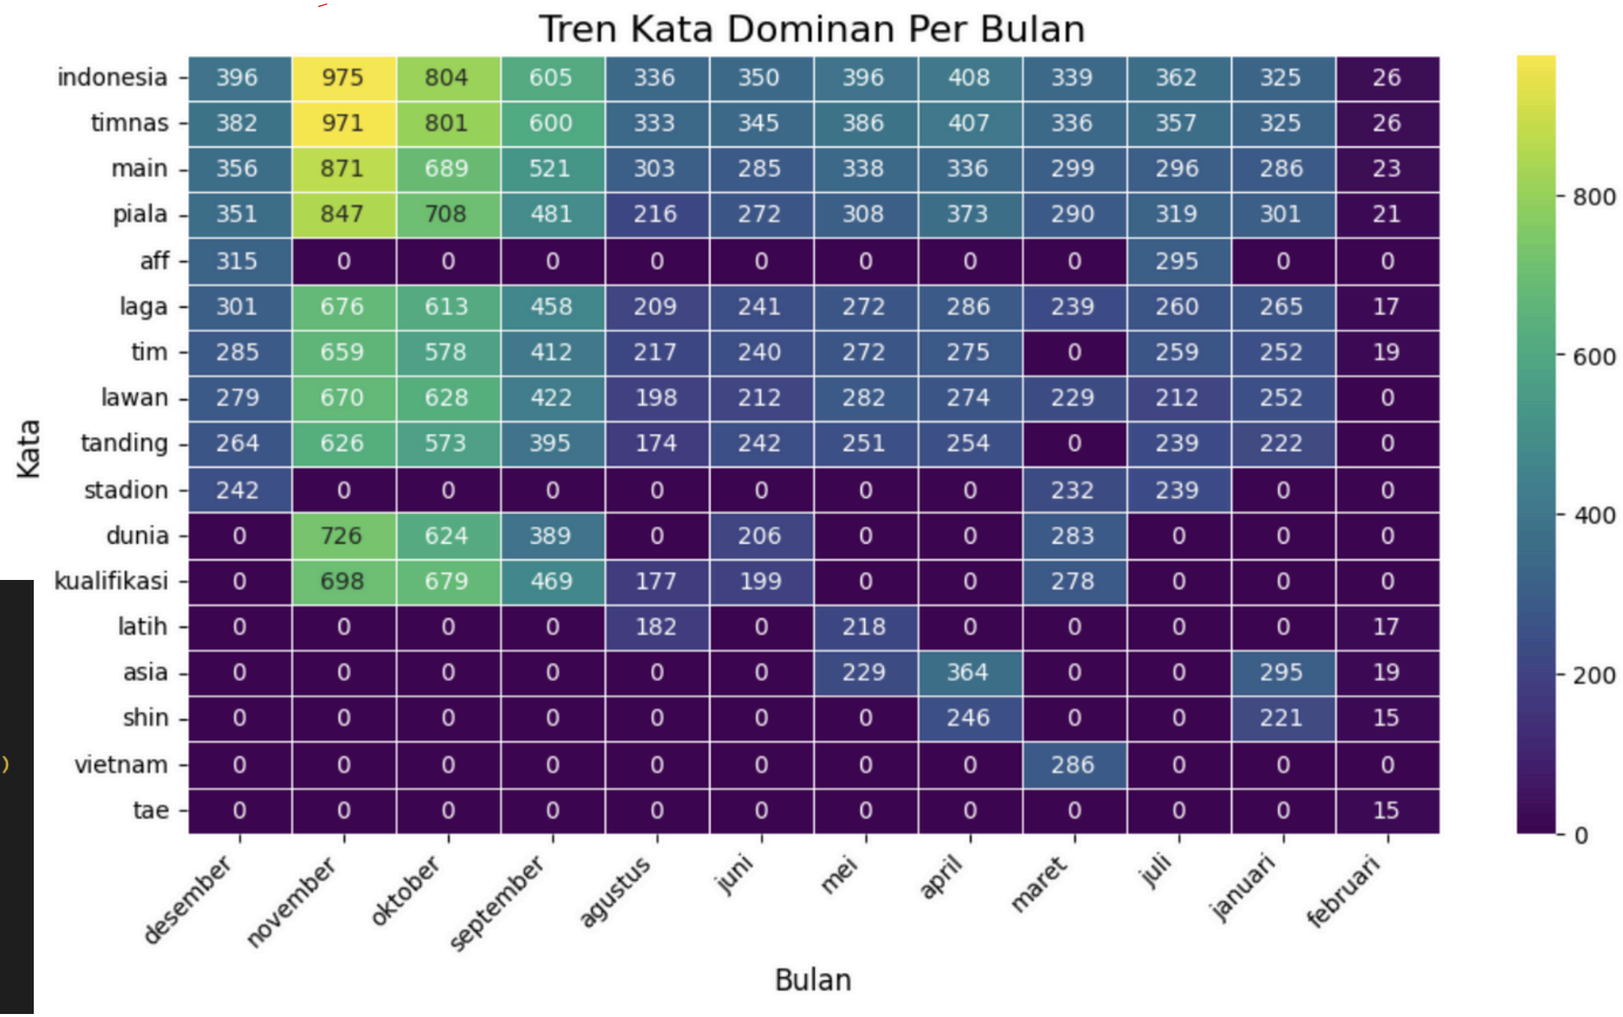

# HIGHLIGHT TOPIC

```
Most Highlighted Topics (Overall):
```

| topic | count |
|---|---|
| Kualifikasi Piala Dunia | 1870 |
| Manajemen Tim dan Pelatihan | 1587 |
| Kejuaraan AFF dan Performa Timnas | 815 |
| Sorotan Pertandingan | 714 |
| Hasil Pertandingan dan Statistik Pemain | 383 |

```python
def count_dominant_words(vdata, month, top_n=10):
    """Counts the dominant words for a given month."""

    month_data = vdata[vdata['month'] == month]
    all_words = []
    for tokens in month_data['tokens']:
      if isinstance(tokens, str):  # Check if tokens is a string
        try:
            all_words.extend(eval(tokens))  # Safely evaluate string representation of the list
        except (NameError, SyntaxError):
            print(f"Skipping invalid 'tokens' value: {tokens}")
            continue  # Skip to the next iteration

    word_counts = {}
    for word in all_words:
      word_counts[word] = word_counts.get(word, 0) + 1

    sorted_word_counts = sorted(word_counts.items(), key=lambda x: x[1], reverse=True)

    return dict(sorted_word_counts[:top_n])

# Analyze dominant words per month
dominant_words_per_month = {}
for month in vdata['month'].unique():
    dominant_words_per_month[month] = count_dominant_words(vdata, month)
# Convert to DataFrame
dominant_words_vdata = pd.DataFrame(dominant_words_per_month).fillna(0).astype(int)

# Count occurrences of each topic across all months
topic_counts = vdata['topic'].value_counts()
top_topics = topic_counts.head(5)

# Print the results: These are the most highlighted topics in the news.
print("\nMost Highlighted Topics (Overall):")
top_topics
```

```python
import matplotlib.pyplot as plt

# Calculate the topic label counts
topic_label_count = vdata['topic'].value_counts()

#Visualisation Month with the most news
plt.figure(figsize=(8, 4))  # Mengatur ukuran gambar
plt.bar(topic_label_count.index, topic_label_count.values) # Use .index and .values
plt.title('Most Topic in 2024')
plt.xlabel('Topic')
plt.ylabel('Count')
plt.xticks(rotation=45, ha='right')  # Memutar label sumbu x dengan arah 45 derajat
plt.show()
```

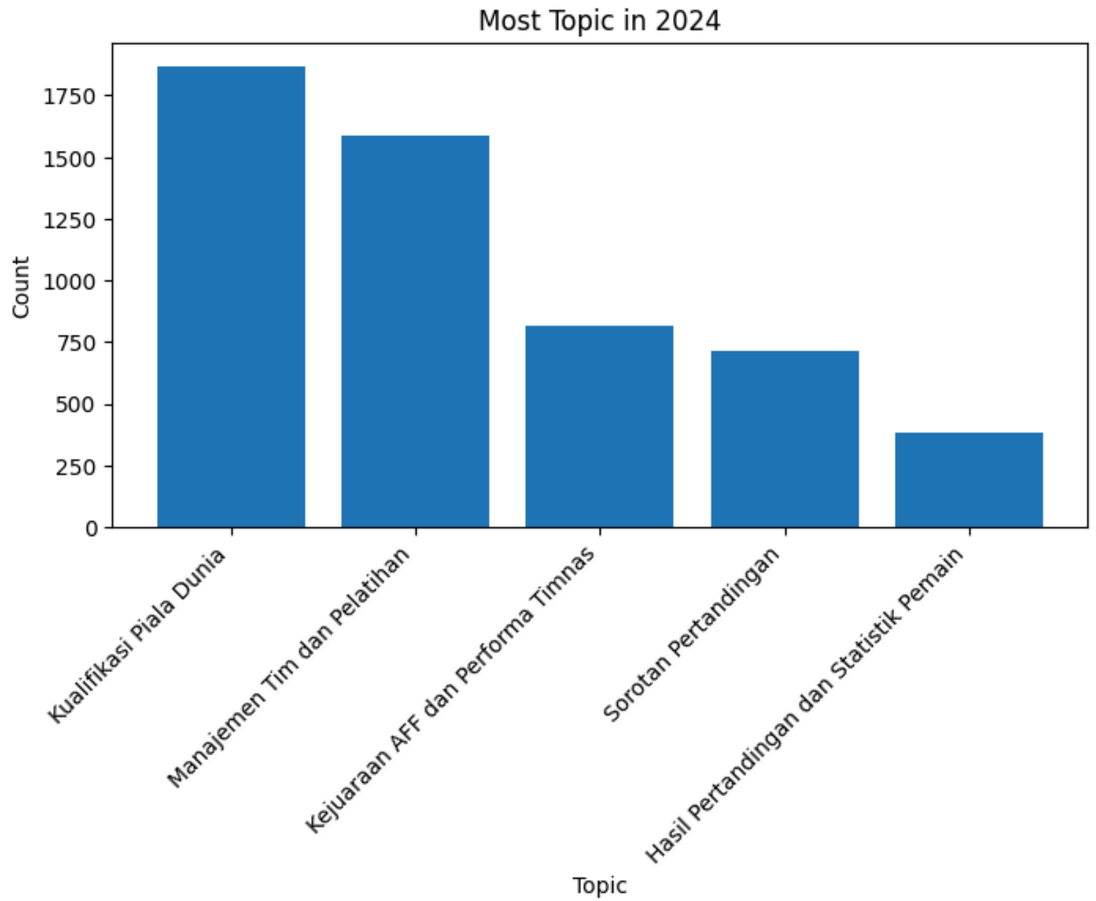

# DISTRIBUSI SENTIMEN BERDASARKAN TOPIK

```python
import pandas as pd

def analyze_sentiment_by_topic(vdata):
    """
    Analyzes the overall sentiment associated with each major topic category.

    Args:
        vdata: pandas DataFrame containing 'topic' and 'sentiment' columns.

    Returns:
        pandas DataFrame: A table summarizing the overall sentiment for each topic.
    """
    # Group by topic and sentiment, count occurrences
    topic_sentiment_counts = vdata.groupby(['topic', 'sentiment']).size().unstack(fill_value=0)

    # Calculate the overall sentiment for each topic
    topic_sentiment_counts['Total'] = topic_sentiment_counts.sum(axis=1)
    topic_sentiment_counts['Positive Ratio'] = topic_sentiment_counts['Positif'] / topic_sentiment_counts['Total']
    topic_sentiment_counts['Negative Ratio'] = topic_sentiment_counts['Negatif'] / topic_sentiment_counts['Total']
    topic_sentiment_counts['Neutral Ratio'] = topic_sentiment_counts['Netral'] / topic_sentiment_counts['Total']

    # Determine the overall sentiment label based on the highest ratio
    topic_sentiment_counts['Overall Sentiment'] = topic_sentiment_counts[['Positive Ratio', 'Negative Ratio', 'Neutral Ratio']].idxmax(axis=1)
    topic_sentiment_counts['Overall Sentiment'] = topic_sentiment_counts['Overall Sentiment'].str.replace(' Ratio', '')

    return topic_sentiment_counts

sentiment_analysis_result = analyze_sentiment_by_topic(vdata)
sentiment_analysis_result
```

| topic | sentiment | Negatif | Netral | Positif | Total | Positive Ratio | Negative Ratio | Neutral Ratio | Overall Sentiment |
|---|---|---|---|---|---|---|---|---|---|
| Hasil Pertandingan dan Statistik Pemain | | 69 | 150 | 164 | 383 | 0.428198 | 0.180157 | 0.391645 | Positive |
| Kejuaraan AFF dan Performa Timnas | | 98 | 445 | 272 | 815 | 0.333742 | 0.120245 | 0.546012 | Neutral |
| Kualifikasi Piala Dunia | | 307 | 1125 | 438 | 1870 | 0.234225 | 0.164171 | 0.601604 | Neutral |
| Manajemen Tim dan Pelatihan | | 283 | 694 | 610 | 1587 | 0.384373 | 0.178324 | 0.437303 | Neutral |
| Sorotan Pertandingan | | 140 | 364 | 210 | 714 | 0.294118 | 0.196078 | 0.509804 | Neutral |

```python
import matplotlib.pyplot as plt
import numpy as np

# Get data for plotting
topics = sentiment_analysis_result.index
positive_ratios = sentiment_analysis_result['Positive Ratio']
negative_ratios = sentiment_analysis_result['Negative Ratio']
neutral_ratios = sentiment_analysis_result['Neutral Ratio']

# Create stacked bar chart
fig, ax = plt.subplots(figsize=(12, 6))
width = 0.35  # Width of the bars
x = np.arange(len(topics))

ax.bar(x, positive_ratios, width, label='Positive', color='green')
ax.bar(x, negative_ratios, width, bottom=positive_ratios, label='Negative', color='red')
ax.bar(x, neutral_ratios, width, bottom=positive_ratios + negative_ratios, label='Neutral', color='blue')

# Add labels and title
ax.set_ylabel('Sentiment Ratio')
ax.set_title('Sentiment Distribution by Topic')
ax.set_xticks(x)
ax.set_xticklabels(topics, rotation=45, ha='right')
ax.legend()

# Display plot
plt.tight_layout()
plt.show()
```

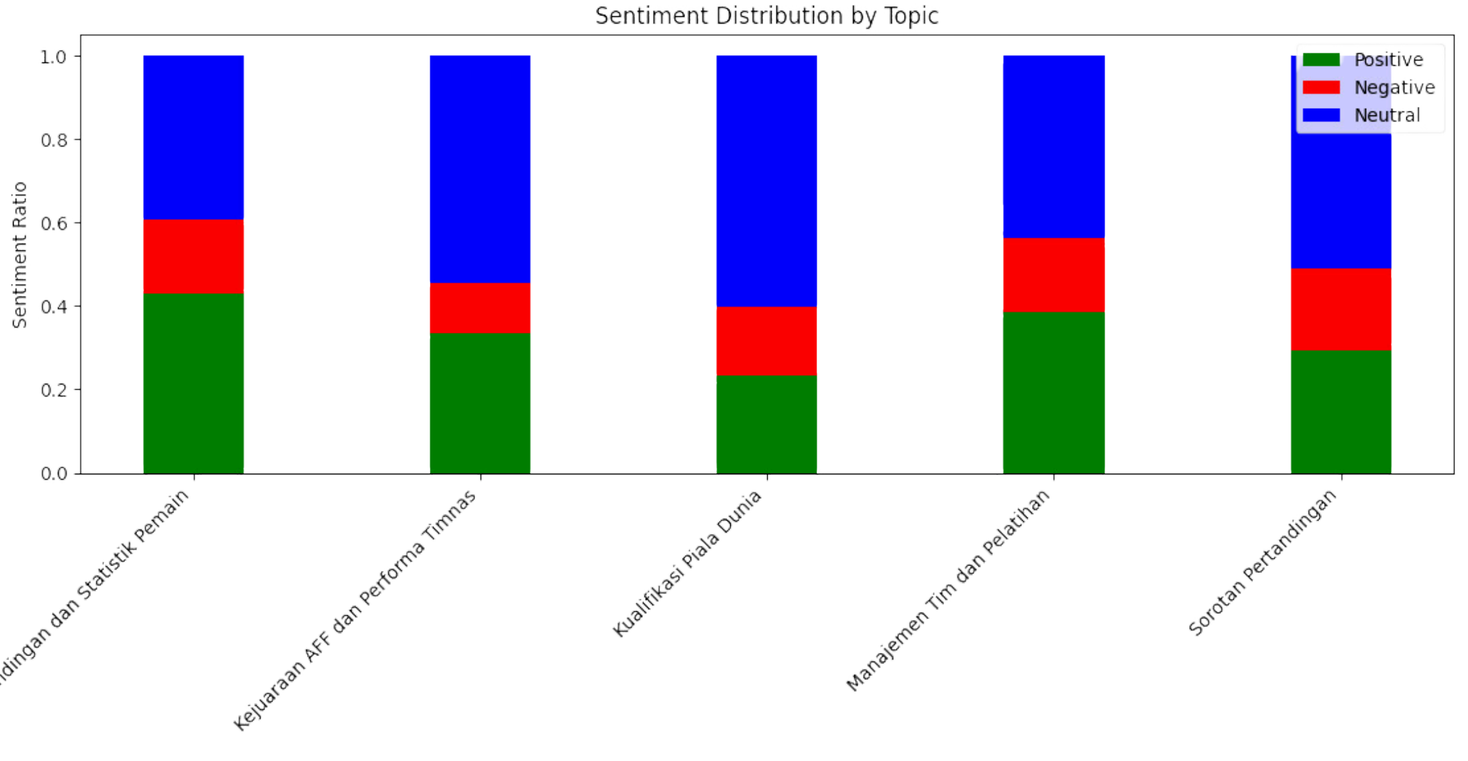

Word Cloud for Sentiment: Positif

Word Cloud for Sentiment: Negatif

WORD CLOUD

Word Cloud for Sentiment: Netral

# STEP BY STEP

# COMBINE DATASET

```
import pandas as pd
import re
```

```
# load dataset hasil scraping dari website
ami = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/dataset/detikArticle3_cleaned_fix.csv')
denta1 = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/dataset/mamamia.csv')
denta2 = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/dataset/cnn.csv')
surya1 = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/dataset/cnn2.csv')
leo = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/dataset/cnn3.csv')
surya2 = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/dataset/cnn_421-840.csv')
dea = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/dataset/kompas_clean1.csv')
basudewa = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/dataset/suara_clean4.csv')
```

```
# menggabungkan semua dataset menjadi 1 data frame
combined_csv = pd.concat([ami, basudewa, denta1, dea, denta2, leo, surya1, surya2], ignore_index=True)
combined_csv.head()
```

| | title | month | content |
|---|---|---|---|
| 0 | Kiper Vietnam Puji Pemain-pemain Muda Timnas I... | Desember | Timnas Vietnam menang atas Indonesia 1-0 di la... |
| 1 | Piala AFF 2024: Ketum PSSI Sanjung Penampilan ... | Desember | Timnas Indonesia kalah melawan Vietnam. Ketua ... |
| 2 | Hitung-hitungan Indonesia Lolos ke Semifinal P... | Desember | Timnas Indonesia kalah dari Vietnam 0-1 di lan... |
| 3 | Statistik Indonesia Vs Vietnam: Timnas Tak Ber... | Desember | Tim nasional Indonesia takluk dari Vietnam di ... |
| 4 | Kerepotan & Ditahan Imbang Laos, Pelajaran Pen... | Desember | Tim nasional Indonesia harus puas dengan hasil... |

```
# cek ukuran data frame
combined_csv.shape
```

```
(9607, 3)
```

Terkumpul 9607 dataset dari berbagai berbagai portal berita!

# CLEANING DATASET

Cek NaN Values

```
# cek nan values
combined_csv.isna().sum()
```

| | 0 |
|---|---|
| title | 97 |
| month | 115 |
| content | 176 |

dtype: int64

BEFORE

```
# menghapus semua nilai nan
combined_csv = combined_csv.dropna()

# cek ulang nilai nan
combined_csv.isna().sum()
```

| | 0 |
|---|---|
| title | 0 |
| month | 0 |
| content | 0 |

dtype: int64

AFTER

```
# menampilkan data duplicate berdasarkan title dengan tetap menampilkan data terakhir yang muncul (data lama)
duplicates = combined_csv[combined_csv.duplicated(subset=["title"], keep='last')]
duplicates
```

| | title | month | content |
|---|---|---|---|
| 62 | Timnas Indonesia Nampang di Kemasan Produk Susu | November | Beberapa pemain Timnas Indonesia akan nampang ... |
| 88 | 11 Pemain Timnas Indonesia Berangkat ke Bahrai... | Oktober | 11 pemain Timnas Indonesia dari Liga 1 sudah d... |
| 89 | Media Arab Saudi: Timnas Indonesia Mengejutkan | September | Arab Saudi hanya bisa bermain imbang 1-1 kontr... |
| 90 | Tiba di Jakarta, Idzes: Timnas Indonesia Butuh... | November | Jay Idzes telah bergabung dengan Timnas Indone... |
| 91 | Ramai-ramai Menanti Aksi Timnas Indonesia | September | Timnas Indonesia tak lama lagi memulai pertaru... |
| ... | ... | ... | ... |
| 6275 | Media Korea Bela STY, Sorot Kritik Erick Thohir | Desember | Media Korea Best Eleven menyoroti pernyataan t... |
| 6276 | Presiden PFF Filipina: Vietnam Tak Mungkin Sel... | Desember | Presiden Federasi Sepak Bola (PFF) Filipina Jo... |
| 6279 | Erick: Timnas Indonesia Habiskan Lebih dari Se... | Desember | Ketua PSSI Erick Thohir menyebut Timnas Indone... |
| 6280 | Sandy Walsh Sebut Banyak Pemain Liga Eropa Ing... | Desember | Sandy Walsh mengaku banyak mendapatkan telepon... |
| 8007 | PSSI Sakit Perut Lihat Realitas Bola Indonesia... | Mei | Anggota Komite Eksekutif (Exco) PSSI Arya Sinu... |

100 rows × 3 columns

Cek Duplicate Data

```
# cek duplicate data berdasarkan title
print(combined_csv.duplicated(subset=['title']).sum())
```

```
100
```

```
# cek duplicate data berdasarkan content
print(combined_csv.duplicated(subset=['content']).sum())
```

```
79
```

```
# cek duplicate data berdasarkan title dan content
print(combined_csv.duplicated(subset=['title', 'content']).sum())
```

```
79
```

Drop Duplicate Data

```
# drop data duplicate berdasarkan title dengan tetap menyimpan data terakhir yang muncul (data lama)
combined_csv.drop_duplicates(subset=['title'], keep='last', inplace=True)

# cek ulang ukuran dataset
combined_csv.shape
```

```
(9303, 3)
```

# PREPROCESSING DATASET

```python
def preprocess_text1(text):
    # ubah ke string dan lowercase
    text = str(text).lower()

    # hapus link urls
    text = re.sub(r'http\S+|www\S+|https\S+', '', text)

    # hapus email
    text = re.sub(r'\S+@\S+', '', text)

    # hapus nomor
    text = re.sub(r'[\+\(]?[1-9][0-9 .\-\(\)]{8,}[0-9]', '', text)

    # hapus kata spesifik
    words_to_remove = ["pukul", "wib", "u", "SUGBK", "bansos", "mk", "rp", "gambas", "video cnn",
                       "wni", "ketum", "cs", "lib", "caf", "v", "vff", "advertisement scroll to continue with content",
                       "senin", "selasa", "rabu", "kamis", "jumat", "sabtu", "minggu", "video", "foto", "ceo",
                       "tc", "pt", "fc", "afc", "wna", "saff", "pers", "pra", "sty", "nec",
                       "ac", "inf", "jam", "exco", "mls", "ibk", "wo", "gbk", "kmsk"]  # Add more words as needed
    pattern = r'\b(?:' + '|'.join(re.escape(word) for word in words_to_remove) + r')\b'
    text = re.sub(pattern, '', text, flags=re.IGNORECASE)

    # hapus special characters dan angka
    text = re.sub(r'[^\w\s]', ' ', text)
    text = re.sub(r'\d+', ' ', text)

    # hapus kata anjay
    text = re.sub(r'\banjay+y+\b', '', text)

    # hapus 1 huruf atau 2 huruf doang
    text = re.sub(r'\b\w{1,2}\b', '', text)

    # hapus extra spasi
    text = re.sub(r'\s+', ' ', text).strip()

    return text
```

Mari kita bersih bersih data agar dapat diproses ke tahap berikutnya!

```python
# implementasi fungsi preprocess_text1 ke title dan content -> disimpan kolom baru clean_title dan clean_content
combined_csv['clean_title'] = combined_csv['title'].apply(preprocess_text1)
combined_csv['clean_content'] = combined_csv['content'].apply(preprocess_text1)
```

```python
# cek ulang ukuran data frame
combined_csv.shape
```

```
(9303, 5)
```

## Content Cleaning

```
# cek data yang mengandung suara com di kolom clean_content
combined_csv[combined_csv['clean_content'].str.contains('suara com')] # Content dari suara.com
```

| | title | month | content | clean_title | clean_content |
|---|---|---|---|---|---|
| 455 | Masih Bisa! Ini Cara Timnas Indonesia Lolos La... | Desember | Suara.com - Peluang Timnas Indonesia untuk bis... | masih bisa ini cara timnas indonesia lolos lan... | suara com peluang timnas indonesia untuk bisa ... |
| 456 | Kabar Buruk, Bek Mahal Timnas Indonesia Cedera... | Desember | Suara.com - Bek timnas Indonesia, Mees Hilgers... | kabar buruk bek mahal timnas indonesia cedera ... | suara com bek timnas indonesia mees hilgers ti... |
| 457 | Komposisi Timnas Indonesia Berubah Terus denga... | Desember | Suara.com - Asisten Shin Tae-yong di timnas In... | komposisi timnas indonesia berubah terus denga... | suara com asisten shin tae yong timnas indones... |
| 458 | Tegas! STY Pulangkan Pemain Keempat dari TC Ti... | Desember | Suara.com - Pelatih Timnas Indonesia, Shin Tae... | tegas pulangkan pemain keempat dari timnas ind... | suara com pelatih timnas indonesia shin tae yo... |
| 459 | Kapan Final Piala AFF Putri 2024? Timnas Indon... | Desember | Suara.com - Final Piala AFF Putri 2024 antara ... | kapan final piala aff putri timnas indonesia a... | suara com final piala aff putri antara timnas ... |
| ... | ... | ... | ... | ... | ... |
| 2763 | Perbandingan Debut Jay Idzes di Serie A Italia... | Agustus | Suara.com - Jay Idzes akhirnya debut bersama V... | perbandingan debut jay idzes serie italia bare... | suara com jay idzes akhirnya debut bersama ven... |
| 2764 | Debut Manis Jay Idzes di Serie A Italia Beruju... | Agustus | Suara.com - Pemain Timnas Indonesia Jay Idzes ... | debut manis jay idzes serie italia berujung pe... | suara com pemain timnas indonesia jay idzes ja... |
| 2765 | Miris! Dulu di Lazio dan Diprediksi Bela Timna... | Agustus | Suara.com - Masih ingat dengan nama Lorenzo Pa... | miris dulu lazio dan diprediksi bela timnas in... | suara com masih ingat dengan nama lorenzo pace... |
| 2766 | Sosok Jay Idzes di Timnas Indonesia Jadi Sorot... | Juli | Suara.com - Kehadiran Jay Idzes di lini belaka... | sosok jay idzes timnas indonesia jadi sorotan ... | suara com kehadiran jay idzes lini belakang ti... |
| 2767 | Timnas Belanda Dicurigai Ingin Ambil Kembali | Juli | Suara.com - Timnas Belanda dicurigai oleh | timnas belanda dicurigai ingin ambil kembali | suara com timnas belanda dicurigai oleh |

```
[ ]  # cek data yang mengandung suara com di kolom clean_title
     combined_csv[combined_csv['clean_title'].str.contains('suara com')] # Content dari suara.com
```

| | title | month | content | clean_title | clean_content |
|---|---|---|---|---|---|

```
[ ]  # hapus string suara com
     combined_csv['clean_content'] = combined_csv['clean_content'].str.replace(r'\bsuara com\b', '', regex=True) # Menghapus string 'suara com'
```

```
[ ]  # cek ulang hasil
     combined_csv[combined_csv['clean_content'].str.contains('suara com')] # Periksa hasil
```

| | title | month | content | clean_title | clean_content |
|---|---|---|---|---|---|

```
[ ]  # cek data yang mengandung cabang daerah suara.com
     combined_csv[combined_csv['clean_content'].str.contains(r'\bsuara\w* id\b', regex=True)] # Content dari
```

| | title | month | content | clean_title | clean_content |
|---|---|---|---|---|---|

```
[ ]  # hapus string cabang daerah suara.com
     combined_csv['clean_content'] = combined_csv['clean_content'].str.replace(r'\bsuara\w* id\b', '', regex=True) # Menghapus string cabang daearah suara.com
```

```
[ ]  # cek hasil
     combined_csv[combined_csv['clean_content'].str.contains(r'\bsuara\w* id\b', regex=True)] # Periksa Hasil
```

| | title | month | content | clean_title | clean_content |
|---|---|---|---|---|---|

```
# cek data yang mengandung kompas com
combined_csv[combined_csv['clean_content'].str.contains('kompas com')] # Content dari kompas.com
```

| | title | month | content | clean_title | clean_content |
|---|---|---|---|---|---|
| 673 | Cek Fakta: Benarkah Gelandang Serang FC Twente... | November | Suara.com - Sebuah video yang beredar di media... | cek fakta benarkah gelandang serang twente sem... | sebuah yang beredar media sosial mengklaim ba... |
| 696 | Cek Fakta: Cristiano Ronaldo Puji Timnas Indon... | November | Suara.com - Belakangan ini, sebuah konten di m... | cek fakta cristiano ronaldo puji timnas indone... | belakangan ini sebuah konten media sosial ram... |
| 3768 | Indonesia Vs Filipina: Erick Thohir Minta STY ... | Desember | KOMPAS.com Ketua Umum PSSI, Erick Thohir angk... | indonesia filipina erick thohir minta fokus ta... | kompas com ketua umum pssi erick thohir angkat... |
| 3769 | Vietnam Disorot, Tak Bisa Menang Meyakinkan at... | Desember | KOMPAS.com - Pengamat sepak bola asal Vietnam,... | vietnam disorot tak bisa menang meyakinkan ata... | kompas com pengamat sepak bola asal vietnam ph... |
| 3770 | Kurs Rupiah di 5 Bank Besar Indonesia Hari Ini... | Desember | JAKARTA, KOMPAS.com - Nilai tukar rupiah terha... | kurs rupiah bank besar indonesia hari ini dese... | jakarta kompas com nilai tukar rupiah terhadap... |
| ... | ... | ... | ... | ... | ... |
| 4086 | Jadwal dan Link Live Streaming Bahrain Vs Indo... | Oktober | KOMPAS.com - Timnas Indonesia akan bertanding ... | jadwal dan link live streaming bahrain indones... | kompas com timnas indonesia akan bertanding me... |
| 4087 | Jadwal Timnas Indonesia Vs Irak di Piala Asia ... | Januari | KOMPAS.com Timnas Indonesia akan bertanding m... | jadwal timnas indonesia irak piala asia besok ... | kompas com timnas indonesia akan bertanding me... |
| 4088 | Jadwal Lengkap Pertandingan di Seoul Earth On ... | Agustus | KOMPAS.com - Usai jadi juara Piala AFF U19, T... | jadwal lengkap pertandingan seoul earth cup la... | kompas com usai jadi juara piala aff timnas in... |

```
# hapus string kompas com
combined_csv['clean_content'] = combined_csv['clean_content'].str.replace(r'kompas com', '', regex=True) # Menghapus string 'kompascom'
```

```
# cek ulang
combined_csv[combined_csv['clean_content'].str.contains('kompas com')] # Periksa hasil
```

| | title | month | content | clean_title | clean_content |
|---|---|---|---|---|---|

```
# cek data yang berawalan jakarta
combined_csv[combined_csv['clean_content'].str.contains(r'^jakarta', regex=True)] # Berita dari kompas.com berawalan 'Jakarta'
```

| | title | month | content | clean_title | clean_content |
|---|---|---|---|---|---|
| 3770 | Kurs Rupiah di 5 Bank Besar Indonesia Hari Ini... | Desember | JAKARTA, KOMPAS.com - Nilai tukar rupiah terha... | kurs rupiah bank besar indonesia hari ini dese... | jakarta nilai tukar rupiah terhadap dollar me... |
| 3772 | Dapat Insentif PPnBM 3 Persen, Ini Daftar Mobi... | Desember | JAKARTA, KOMPAS.com - Pemerintah melalui Mente... | dapat insentif ppnbm persen ini daftar mobil h... | jakarta pemerintah melalui menteri koordinato... |
| 3775 | Catat! Jadwal Pembagian Dividen Interim BRI Rp... | Desember | JAKARTA, KOMPAS.com Kabar baik bagi para peme... | catat jadwal pembagian dividen interim bri per... | jakarta kabar baik bagi para pemegang saham b... |
| 3778 | Sudah 15 Tahun Merantau ke Luar Negeri, Nadia ... | Desember | JAKARTA, KOMPAS.com- Aktris Nadia Vega terkeju... | sudah tahun merantau luar negeri nadia vega te... | jakarta aktris nadia vega terkejut melihat pe... |
| 3783 | Alfamart Tutup Ratusan Toko, Ritel Indonesia B... | Desember | JAKARTA, KOMPAS.com - Himpunan Peritel dan Pen... | alfamart tutup ratusan toko ritel indonesia be... | jakarta himpunan peritel dan penyewa pusat pe... |
| 3787 | Hyundai Mengaku Lagi Siapkan Produk Khusus Ind... | Desember | JAKARTA, KOMPAS.com - PT Hyundai Motors Indone... | hyundai mengaku lagi siapkan produk khusus ind... | jakarta hyundai motors indonesia hmid terus m... |

```
# cek data yang berawalan sidoarjo
combined_csv[combined_csv['clean_content'].str.contains(r'^sidoarjo', regex=True)] # Berita dari kompas.com berawalan 'Sidoarjo'
```

| title | month | content | clean_title | clean_content |
|---|---|---|---|---|

```
# cek data yang berawalan cikarang
combined_csv[combined_csv['clean_content'].str.contains(r'^cikarang', regex=True)] # Berita dari kompas.com berawalan 'Cikarang'
```

| title | month | content | clean_title | clean_content |
|---|---|---|---|---|

```
# cek data yang berawalan surabaya
combined_csv[combined_csv['clean_content'].str.contains(r'^surabaya', regex=True)] # Berita dari kompas.com berawalan 'Surabaya'
```

| title | month | content | clean_title | clean_content |
|---|---|---|---|---|

```
# cek data yang berawalan singapura
combined_csv[combined_csv['clean_content'].str.contains(r'^singapura', regex=True)] # Berita dari kompas.com berawalan 'Singapura'
```

| title | month | content | clean_title | clean_content |
|---|---|---|---|---|

```
# cek data yang berawalan batu
combined_csv[combined_csv['clean_content'].str.contains(r'^batu', regex=True)] # Berita dari kompas.com berawalan 'Batu'
```

| title | month | content | clean_title | clean_content |
|---|---|---|---|---|

```
# hapus string jakarta, singapura, sidoarjo, cikarang, surabaya, batu
combined_csv['clean_content'] = combined_csv['clean_content'].str.replace(r'^jakarta', '', regex=True) # Menghapus string 'jakarta' di awal
combined_csv['clean_content'] = combined_csv['clean_content'].str.replace(r'^singapura', '', regex=True) # Menghapus string 'singapura' di awal
combined_csv['clean_content'] = combined_csv['clean_content'].str.replace(r'^sidoarjo', '', regex=True) # Menghapus string 'sidoarjo' di awal
combined_csv['clean_content'] = combined_csv['clean_content'].str.replace(r'^cikarang', '', regex=True) # Menghapus string 'cikarang' di awal
combined_csv['clean_content'] = combined_csv['clean_content'].str.replace(r'^surabaya', '', regex=True) # Menghapus string 'surabaya' di awal
combined_csv['clean_content'] = combined_csv['clean_content'].str.replace(r'^batu', '', regex=True) # Menghapus string 'batu' di awal
```

```
# cek data yang mengandung bola com
combined_csv[combined_csv['clean_content'].str.contains(r'bola com', regex=True)] # Content dari bola.com
```

| | title | month | content | clean_title | clean_content |
|---|---|---|---|---|---|
| 2026 | Terlepas dari Kebobolan 4 Gol, Statistik Timna... | Januari | Timnas Indonesia senior harus merasakan hasil ... | terlepas dari kebobolan gol statistik timnas i... | timnas indonesia senior harus merasakan hasil ... |

```
# hapus string bola com
combined_csv['clean_content'] = combined_csv['clean_content'].replace(r'bola com', '', regex=True) # Menghapus string 'bolacom' di awal yang diikuti nama daerah
```

```
# cek ulang
combined_csv[combined_csv['clean_content'].str.contains(r'bola com', regex=True)]
```

| title | month | content | clean_title | clean_content |
|---|---|---|---|---|

```
# gabungkan kolom clean_title dan clean_content
combined_csv['full_text'] = combined_csv['clean_title'] + ' ' + combined_csv['clean_content']
```

```
# cek data
combined_csv.head()
```

| | title | month | content | clean_title | clean_content | full_text |
|---|---|---|---|---|---|---|
| 0 | Kiper Vietnam Puji Pemain-pemain Muda Timnas I... | Desember | Timnas Vietnam menang atas Indonesia 1-0 di la... | kiper vietnam puji pemain pemain muda timnas i... | timnas vietnam menang atas indonesia lanjutan ... | kiper vietnam puji pemain pemain muda timnas i... |
| 1 | Piala AFF 2024: Ketum PSSI Sanjung Penampilan ... | Desember | Timnas Indonesia kalah melawan Vietnam. Ketua ... | piala aff pssi sanjung penampilan timnas indon... | timnas indonesia kalah melawan vietnam ketua u... | piala aff pssi sanjung penampilan timnas indon... |
| 2 | Hitung-hitungan Indonesia Lolos ke Semifinal P... | Desember | Timnas Indonesia kalah dari Vietnam 0-1 di lan... | hitung hitungan indonesia lolos semifinal pial... | timnas indonesia kalah dari vietnam lanjutan g... | hitung hitungan indonesia lolos semifinal pial... |
| 3 | Statistik Indonesia Vs Vietnam: Timnas Tak Ber... | Desember | Tim nasional Indonesia takluk dari Vietnam di ... | statistik indonesia vietnam timnas tak berkutik | tim nasional indonesia takluk dari vietnam lan... | statistik indonesia vietnam timnas tak berkuti... |
| 4 | Kerepotan & Ditahan Imbang Laos, Pelajaran Pen... | Desember | Tim nasional Indonesia harus puas dengan hasil... | kerepotan ditahan imbang laos pelajaran pentin... | tim nasional indonesia harus puas dengan hasil... | kerepotan ditahan imbang laos pelajaran pentin... |

# DATA FILTERING

## Data Filtering

```
[ ]  # exclude semua data (full_text) yang mengandung keyword tertentu
     filter1 = combined_csv[~combined_csv['full_text'].str.contains(r'putri|wanita|futsal|link|streaming|tiket|sayembara|timnas belanda dicurigai|jerome|innalillahi|kakek|ayah|mantan|meme|bank|voli|cak imin|anies|ganja

     # cek ukuran data frame
     filter1.shape
```

```
(5369, 6)
```

```
[ ]  # dataset test
     filter1.to_csv('/content/drive/MyDrive/capstone mikti/combine code/test dataset/test.csv', index=False)
```

# STOP WORDS

## Stop words

adding custom stopwords, source:

- https://github.com/nolimitid/nolimit-kamus/blob/master/indonesian-stopwords-complete.txt
- https://github.com/faiqpurnomo/StopWords-Indonesia/blob/master/stopwords.txt

```
[ ]  !pip install Sastrawi
```

```
Requirement already satisfied: Sastrawi in /usr/local/lib/python3.10/dist-packages (1.0.1)
```

```
import nltk
from nltk.corpus import stopwords
from Sastrawi.StopWordRemover.StopWordRemoverFactory import StopWordRemoverFactory

nltk.download('punkt_tab')
nltk.download('stopwords')
```

```
[nltk_data] Downloading package punkt_tab to /root/nltk_data...
[nltk_data]   Package punkt_tab is already up-to-date!
[nltk_data] Downloading package stopwords to /root/nltk_data...
[nltk_data]   Package stopwords is already up-to-date!
True
```

```
# menyiapkan stopword dengan sastrawi
sastrawi_stops = StopWordRemoverFactory().get_stop_words()
nltk_stops = set(stopwords.words('indonesian'))

# menambahkan custom stopword dari github
with open('/content/drive/MyDrive/capstone mikti/combine code/additional data/stopwords.txt', 'r', encoding='utf-8') as f:
    custom_stopwords1 = set(line.strip() for line in f)

# menambahkan custom stopword dari github
with open('/content/drive/MyDrive/capstone mikti/combine code/additional data/indonesian-stopwords-complete.txt', 'r', encoding='utf-8') as f:
    custom_stopwords2 = set(line.strip() for line in f)

# gabung semua stopwords
stopwords = set(sastrawi_stops) | nltk_stops | custom_stopwords1 | custom_stopwords2
```

```
def remove_stopwords(text):
    # split text
    words = text.split()

    # implementasi stopwords
    filtered_words = [word for word in words if word.lower() not in stopwords]

    # gabung habis difilter ke string
    return " ".join(filtered_words)
```

```
# apply function remove_stopwords
filter1.loc[:, 'clean_full_text'] = filter1['full_text'].apply(remove_stopwords)
```

```
<ipython-input-225-9079aa81af83>:2: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  filter1.loc[:, 'clean_full_text'] = filter1['full_text'].apply(remove_stopwords)
```

# STEMMING

## Stemming

```
[ ]  # import stemmer dengan sastrawi
     from Sastrawi.Stemmer.StemmerFactory import StemmerFactory
```

```
[ ]  # inisialisasi stemmer
     factory = StemmerFactory()
     stemmer = factory.create_stemmer()
```

```
[ ]  # apply stemmer
     filter1.loc[:, 'clean_full_text'] = filter1['clean_full_text'].apply(stemmer.stem)
```

```
     # cek data
     filter1.head()
```

| | title | month | content | clean_title | clean_content | full_text | clean_full_text |
|---|---|---|---|---|---|---|---|
| 0 | Kiper Vietnam Puji Pemain-pemain Muda Timnas I... | Desember | Timnas Vietnam menang atas Indonesia 1-0 di la... | kiper vietnam puji pemain pemain muda timnas i... | timnas vietnam menang atas indonesia lanjutan ... | kiper vietnam puji pemain pemain muda timnas i... | kiper vietnam puji main main muda timnas indon... |
| 1 | Piala AFF 2024: Ketum PSSI Sanjung Penampilan ... | Desember | Timnas Indonesia kalah melawan Vietnam. Ketua ... | piala aff pssi sanjung penampilan timnas indon... | timnas indonesia kalah melawan vietnam ketua u... | piala aff pssi sanjung penampilan timnas indon... | piala aff pssi sanjung tampil timnas indonesia... |
| 4 | Kerepotan & Ditahan Imbang Laos, Pelajaran Pen... | Desember | Tim nasional Indonesia harus puas dengan hasil... | kerepotan ditahan imbang laos pelajaran pentin... | tim nasional indonesia harus puas dengan hasil... | kerepotan ditahan imbang laos pelajaran pentin... | kerepot tahan imbang laos ajar timnas indonesi... |
| 5 | Susunan Pemain Timnas Indonesia Vs Laos: Strui... | Desember | Timnas Indonesia menjamu Laos dalam matchday k... | susunan pemain timnas indonesia laos struick s... | timnas indonesia menjamu laos dalam matchday k... | susunan pemain timnas indonesia laos struick s... | susun main timnas indonesia laos struick start... |
| 6 | Meski Dikalahkan Vietnam, STY Pede Indonesia k... | Desember | Kekalahan Timnas Indonesia dari Vietnam tidak ... | meski dikalahkan vietnam pede indonesia semifinal | kekalahan timnas indonesia dari vietnam tidak ... | meski dikalahkan vietnam pede indonesia semifi... | kalah vietnam pede indonesia semifinal kalah t... |

# NORMALIZE TEXT PT 2

## Normalize text part 2

```
[ ]  def preprocess_text2(text):
         # hapus kata tertentu
         words_to_remove = ["a", "b", "c", "d", "e", "f", "g", "h", "i", "j", "k", "l", "m", "n", "o",
                            "p", "q", "r", "s", "t", "u", "v", "w", "x", "y", "z", "grup"]

         # hapus kata tertentu dari teks berdasarkan words_to_remove
         pattern = r'\b(?:' + '|'.join(re.escape(word) for word in words_to_remove) + r')\b'
         text = re.sub(pattern, '', text, flags=re.IGNORECASE)

         # split word
         words = text.split()

         # hapus duplikasi kata, menyisakan kata unique
         unique_words = list(dict.fromkeys(words))  # Preserve the order and remove duplicates

         return ' '.join(unique_words)
```

```
     # apply function preprocess_text2
     filter1.loc[:, 'clean_full_text'] = filter1['clean_full_text'].apply(preprocess_text2)
```

```
[ ]  # perpanjang vs -> versus
     abbreviations = {
         "vs": "versus"
     }

     # ganti string vs dengan versus ke semua data
     filter1.loc[:, 'clean_full_text'] = filter1['clean_full_text'].replace(abbreviations, regex=True)
```

# TOPIC MODELING - LDA

## Topic Modeling: using LDA

```
[ ]  # import library yang dibutuhkan
     from gensim.models import LdaModel
     from gensim.corpora import Dictionary
     from nltk.tokenize import word_tokenize
```

```
[ ]  # tokenisasi kolom cleaned_full_text ke tokens
     df['tokens'] = df['clean_full_text'].apply(word_tokenize)

     # inisialisasi dictionary dan corpus (doc2bow) untuk LDA
     dictionary = Dictionary(df['tokens'])
     corpus = [dictionary.doc2bow(text) for text in df['tokens']]
```

```
     # train LDA model
     lda_model = LdaModel(corpus, num_topics=5, id2word=dictionary, passes=10)

     # tampilkan top words tiap topik
     for idx, topic in lda_model.show_topics(num_topics=5, num_words=10, formatted=False):
         print(f"Topic {idx}: {[word for word, _ in topic]}")
```

```
Topic 0: ['liga', 'united', 'persib', 'bandung', 'indonesia', 'klub', 'timnas', 'main', 'mas', 'surabaya']
Topic 1: ['gol', 'menit', 'cetak', 'main', 'gawang', 'indonesia', 'timnas', 'laga', 'penalti', 'stadion']
Topic 2: ['timnas', 'indonesia', 'main', 'piala', 'dunia', 'kualifikasi', 'lawan', 'shin', 'yong', 'tae']
Topic 3: ['piala', 'indonesia', 'timnas', 'tim', 'laga', 'lawan', 'tanding', 'asia', 'main', 'menang']
Topic 4: ['indonesia', 'timnas', 'main', 'bola', 'sepak', 'liga', 'tim', 'media', 'salah', 'milik']
```

```
# masukkan topik dominan tiap dokumen
def get_dominant_topic(lda_model, corpus):
    dominant_topics = []
    for doc in lda_model[corpus]:
        dominant_topic = sorted(doc, key=lambda x: x[1], reverse=True)[0][0]
        dominant_topics.append(dominant_topic)
    return dominant_topics

# apply function get_dominant_topic
df['topic'] = get_dominant_topic(lda_model, corpus)
```

```
# import untuk sentiment topic
from nltk.sentiment import SentimentIntensityAnalyzer
```

```
nltk.download('vader_lexicon')
```

```
[nltk_data] Downloading package vader_lexicon to /root/nltk_data...
True
```

```
# inisialisasi sentiment analyzer
sia = SentimentIntensityAnalyzer()

# hitung sentiment tiap dokumen
df['dominant_topic'] = df['clean_full_text'].apply(lambda x: sia.polarity_scores(x)['compound'])

# rata-rata sentiment tiap topic
sentiment_per_topic = df.groupby('topic')['dominant_topic'].mean()
print(sentiment_per_topic)
```

```
topic
0    0.202831
1    0.074985
2    0.061730
3    0.054970
4    0.115396
Name: dominant_topic, dtype: float64
```

# TOPIC MODELING - LDA

```python
# buat main topic yang akan digunakan
topic_mapping = {
    0: "Kejuaraan AFF dan Performa Timnas",
    1: "Kualifikasi Piala Dunia",
    2: "Manajemen Tim dan Pelatihan",
    3: "Sorotan Pertandingan",
    4: "Hasil Pertandingan dan Statistik Pemain"
}

# ganti angka dengan main topic diatas
df['topic'] = df['topic'].map(topic_mapping)
```

```python
# cek data
df.head()
```

| | month | clean_full_text | tokens | topic | dominant_topic |
|---|---|---|---|---|---|
| 0 | desember | kiper vietnam puji main muda timnas indonesia ... | [kiper, vietnam, puji, main, muda, timnas, ind... | Sorotan Pertandingan | 0.3612 |
| 1 | desember | piala aff pssi sanjung tampil timnas indonesia... | [piala, aff, pssi, sanjung, tampil, timnas, in... | Sorotan Pertandingan | 0.0000 |
| 4 | desember | kerepot tahan imbang laos ajar timnas indonesi... | [kerepot, tahan, imbang, laos, ajar, timnas, i... | Sorotan Pertandingan | 0.0000 |
| 5 | desember | susun main timnas indonesia laos struick start... | [susun, main, timnas, indonesia, laos, struick... | Kualifikasi Piala Dunia | 0.5423 |
| 6 | desember | kalah vietnam pede indonesia semifinal timnas ... | [kalah, vietnam, pede, indonesia, semifinal, t... | Sorotan Pertandingan | 0.0000 |

```python
# dataset test4
df.to_csv('/content/drive/MyDrive/capstone mikti/combine code/test dataset/test4.csv', index=False)
```

```python
# load dataset yang lebih akurat sebelumnya
df = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/test dataset/test4.csv')
df.head()
```

| | month | clean_full_text | tokens | topic | dominant_topic |
|---|---|---|---|---|---|
| 0 | desember | kiper vietnam puji main muda timnas indonesia ... | ['kiper', 'vietnam', 'puji', 'main', 'muda', '... | Kualifikasi Piala Dunia | 0.3612 |
| 1 | desember | piala aff pssi sanjung tampil timnas indonesia... | ['piala', 'aff', 'pssi', 'sanjung', 'tampil', ... | Kualifikasi Piala Dunia | 0.0000 |
| 2 | desember | kerepot tahan imbang laos ajar timnas indonesi... | ['kerepot', 'tahan', 'imbang', 'laos', 'ajar',... | Kualifikasi Piala Dunia | 0.0000 |
| 3 | desember | susun main timnas indonesia laos struick start... | ['susun', 'main', 'timnas', 'indonesia', 'laos... | Manajemen Tim dan Pelatihan | 0.5423 |
| 4 | desember | kalah vietnam pede indonesia semifinal timnas ... | ['kalah', 'vietnam', 'pede', 'indonesia', 'sem... | Kualifikasi Piala Dunia | 0.0000 |

```python
# cek data masing-masing topic
df['topic'].value_counts()
```

| topic | count |
|---|---|
| Kualifikasi Piala Dunia | 1870 |
| Manajemen Tim dan Pelatihan | 1587 |
| Kejuaraan AFF dan Performa Timnas | 815 |
| Sorotan Pertandingan | 714 |
| Hasil Pertandingan dan Statistik Pemain | 383 |

dtype: int64

```python
# hapus kolom dominant_topic
df = df.drop(['dominant_topic'], axis=1)
```

# SENTIMENT ANALYSIS: POSITIVE, NEGATIVE, AND NEUTRAL

```
!pip install VaderSentiment
```

```
Requirement already satisfied: VaderSentiment in /usr/local/lib/python3.10/dist-packages (3.3.2)
Requirement already satisfied: requests in /usr/local/lib/python3.10/dist-packages (from VaderSentiment) (2.32.3)
Requirement already satisfied: charset-normalizer<4,>=2 in /usr/local/lib/python3.10/dist-packages (from requests->VaderSentiment) (3.4.0)
Requirement already satisfied: idna<4,>=2.5 in /usr/local/lib/python3.10/dist-packages (from requests->VaderSentiment) (3.10)
Requirement already satisfied: urllib3<3,>=1.21.1 in /usr/local/lib/python3.10/dist-packages (from requests->VaderSentiment) (2.2.3)
Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.10/dist-packages (from requests->VaderSentiment) (2024.12.14)
```

```
# load dataset test5
df1 = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/test dataset/test5.csv')
df1.head()
```

| | month | clean_full_text | tokens | topic |
|---|---|---|---|---|
| 0 | desember | kiper vietnam puji main muda timnas indonesia ... | ['kiper', 'vietnam', 'puji', 'main', 'muda', '... | Kualifikasi Piala Dunia |
| 1 | desember | piala aff pssi sanjung tampil timnas indonesia... | ['piala', 'aff', 'pssi', 'sanjung', 'tampil', ... | Kualifikasi Piala Dunia |
| 2 | desember | kerepot tahan imbang laos ajar timnas indonesi... | ['kerepot', 'tahan', 'imbang', 'laos', 'ajar',... | Kualifikasi Piala Dunia |
| 3 | desember | susun main timnas indonesia laos struick start... | ['susun', 'main', 'timnas', 'indonesia', 'laos... | Manajemen Tim dan Pelatihan |
| 4 | desember | kalah vietnam pede indonesia semifinal timnas ... | ['kalah', 'vietnam', 'pede', 'indonesia', 'sem... | Kualifikasi Piala Dunia |

```
from vaderSentiment.vaderSentiment import SentimentIntensityAnalyzer

# inisialisasi sentiment analyzer
analyzer = SentimentIntensityAnalyzer()
```

# SENTIMENT ANALYSIS: POSITIVE, NEGATIVE, AND NEUTRAL

```
# apply sentimen positif, negatif, netral berdasarkan analyzer
df1['sentiment'] = df1['clean_full_text'].apply(lambda x: 'Positif' if analyzer.polarity_scores(x)['compound'] > 0 else ('Negatif' if analyzer.polarity_scores(x)['compound'] < 0 else 'Netral'))

# cek data
df1
```

| | month | clean_full_text | tokens | topic | sentiment |
|---|---|---|---|---|---|
| 0 | desember | kiper vietnam puji main muda timnas indonesia ... | ['kiper', 'vietnam', 'puji', 'main', 'muda', '... | Kualifikasi Piala Dunia | Positif |
| 1 | desember | piala aff pssi sanjung tampil timnas indonesia... | ['piala', 'aff', 'pssi', 'sanjung', 'tampil', ... | Kualifikasi Piala Dunia | Netral |
| 2 | desember | kerepot tahan imbang laos ajar timnas indonesi... | ['kerepot', 'tahan', 'imbang', 'laos', 'ajar',... | Kualifikasi Piala Dunia | Netral |
| 3 | desember | susun main timnas indonesia laos struick start... | ['susun', 'main', 'timnas', 'indonesia', 'laos... | Manajemen Tim dan Pelatihan | Positif |
| 4 | desember | kalah vietnam pede indonesia semifinal timnas ... | ['kalah', 'vietnam', 'pede', 'indonesia', 'sem... | Kualifikasi Piala Dunia | Netral |
| ... | ... | ... | ... | ... | ... |
| 5364 | januari | timnas indonesia dominan kuasa bola sulit cipt... | ['timnas', 'indonesia', 'dominan', 'kuasa', 'b... | Kualifikasi Piala Dunia | Netral |
| 5365 | januari | reaksi netizen indonesia cukur libya gimana pi... | ['reaksi', 'netizen', 'indonesia', 'cukur', 'l... | Manajemen Tim dan Pelatihan | Positif |
| 5366 | januari | debut justin hubner timnas indonesia laku blun... | ['debut', 'justin', 'hubner', 'timnas', 'indon... | Sorotan Pertandingan | Negatif |
| 5367 | januari | kalah telak libya timnas indonesia solid piala... | ['kalah', 'telak', 'libya', 'timnas', 'indones... | Kualifikasi Piala Dunia | Positif |
| 5368 | januari | hasil uji coba jelang piala asia timnas indone... | ['hasil', 'uji', 'coba', 'jelang', 'piala', 'a... | Sorotan Pertandingan | Negatif |

5369 rows × 5 columns

```
# hitung data positif, negatif, netral
df1['sentiment'].value_counts()
```

| sentiment | count |
|---|---|
| Netral | 2778 |
| Positif | 1694 |
| Negatif | 897 |

dtype: int64

# PREDICT MODEL

## Predictive Model

```
df2 = pd.read_csv('/content/drive/MyDrive/capstone mikti/combine code/dataset/final_dataset.csv')
df2.head()
```

| | month | clean_full_text | tokens | topic | sentiment |
|---|---|---|---|---|---|
| 0 | desember | kiper vietnam puji main muda timnas indonesia ... | ['kiper', 'vietnam', 'puji', 'main', 'muda', '... | Kualifikasi Piala Dunia | Positif |
| 1 | desember | piala aff pssi sanjung tampil timnas indonesia... | ['piala', 'aff', 'pssi', 'sanjung', 'tampil', ... | Kualifikasi Piala Dunia | Netral |
| 2 | desember | kerepot tahan imbang laos ajar timnas indonesi... | ['kerepot', 'tahan', 'imbang', 'laos', 'ajar',... | Kualifikasi Piala Dunia | Netral |
| 3 | desember | susun main timnas indonesia laos struick start... | ['susun', 'main', 'timnas', 'indonesia', 'laos... | Manajemen Tim dan Pelatihan | Positif |
| 4 | desember | kalah vietnam pede indonesia semifinal timnas ... | ['kalah', 'vietnam', 'pede', 'indonesia', 'sem... | Kualifikasi Piala Dunia | Netral |

# MAPPING SENTIMENT

## Mapping Sentiment

```
sentiment_mapping = {
    'Negatif': 0,
    'Netral': 1,
    'Positif': 2,
}
```

```
df2['sentiment'] = df2['sentiment'].apply(lambda x: sentiment_mapping[x]) # Mengubah nilai sentimen dari text menjadi numerik
```

```
df.head()
```

| | month | clean_full_text | tokens | topic |
|---|---|---|---|---|
| 0 | desember | kiper vietnam puji main muda timnas indonesia ... | ['kiper', 'vietnam', 'puji', 'main', 'muda', '... | Kualifikasi Piala Dunia |
| 1 | desember | piala aff pssi sanjung tampil timnas indonesia... | ['piala', 'aff', 'pssi', 'sanjung', 'tampil', ... | Kualifikasi Piala Dunia |
| 2 | desember | kerepot tahan imbang laos ajar timnas indonesi... | ['kerepot', 'tahan', 'imbang', 'laos', 'ajar',... | Kualifikasi Piala Dunia |
| 3 | desember | susun main timnas indonesia laos struick start... | ['susun', 'main', 'timnas', 'indonesia', 'laos... | Manajemen Tim dan Pelatihan |
| 4 | desember | kalah vietnam pede indonesia semifinal timnas ... | ['kalah', 'vietnam', 'pede', 'indonesia', 'sem... | Kualifikasi Piala Dunia |

# SPLITTING DATA

**Splitting Data**

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(df2['clean_full_text'], df2['sentiment'], test_size=0.15, random_state=42) # Split data, 15% testing 85% latih
```

# FEATURE EXTRACTION

**Feature Extraction**

```
from sklearn.feature_extraction.text import TfidfVectorizer

vectorizer = TfidfVectorizer(max_features=5000) # Vectorizer dengan fitur maksimal 5000

# Mengubah data menjadi vektor
X_train_vec = vectorizer.fit_transform(X_train).toarray()
X_test_vec = vectorizer.transform(X_test).toarray()
```

# MODEL

**Model**

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GridSearchCV

model = RandomForestClassifier(random_state=42)

# Hyperparameter Tuning
param_grid = {
    'n_estimators': [100, 200, 300],
    'max_depth': [None, 10, 20, 30],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [1, 2, 4]
}

grid_search = GridSearchCV(estimator=model, param_grid=param_grid,
                           scoring='f1_macro', cv=3, verbose=2, n_jobs=-1)

grid_search.fit(X_train_vec, y_train)
```

```
Fitting 3 folds for each of 108 candidates, totalling 324 fits
```

```
# Mengambil hyperparameter terbaik
best_params = grid_search.best_params_
best_model = grid_search.best_estimator_

print(best_params)
```

# EVALUATE MODEL

## Evaluate Model

```
from sklearn.metrics import classification_report, confusion_matrix, accuracy_score, ConfusionMatrixDisplay
import matplotlib.pyplot as plt

y_pred = best_model.predict(X_test_vec) # Membuat prediksi dengan model

print("Accuracy:", accuracy_score(y_test, y_pred))

print("\nClassification Report:")
print(classification_report(y_test, y_pred, target_names=["negative", "neutral", "positive"]))

class_names = ["negative", "neutral", "positive"]

disp = ConfusionMatrixDisplay(confusion_matrix=confusion_matrix(y_test, y_pred), display_labels=class_names)
disp.plot(cmap='Reds', values_format='d')
plt.title('Confusion Matrix')
plt.show()
```

# QnA

# THANK YOU SO MUCH